

# Ile kosztuje wytrenowanie małego modelu językowego? Szybkość i cena treningu na wynajmowanych i własnych kartach graficznych

Arkadiusz Słota

2 października 2026 — krótka nota, wersja 2 (tylko pomiary z naszych dotychczasowych  
biegów)

## Streszczenie

Odpowiadamy na jedno praktyczne pytanie: jeśli chcemy wytrenować model danej wielkości na danej liczbie tokenów, jaką kartę wynająć, ile to potrwa i ile będzie kosztować? Ta pierwsza wersja korzysta tylko z pomiarów z naszych własnych biegów (modele od 31 mln do 253 mln parametrów, na RTX 5090, RTX Pro 6000 i Radeon RX 7900 XTX) oraz z publicznego cennika RunPod z 2 października 2026. Trzy wnioski: przy modelach do około 64 mln parametrów szybkość ogranicza procesor serwera, a nie karta, więc ta sama RTX 5090 daje od 250 000 do 363 000 tokenów na sekundę; RTX 5090 jest najtańsza w przeliczeniu na token we wszystkim, co dotąd zmierzaliśmy (0,53–2,14 USD za miliard tokenów); dwie karty trenują szybciej niż jedna, ale token kosztuje o 25 % więcej. Następna wersja doda karty, których jeszcze nie używaliśmy (RTX 3090, 4090, A100, H100 i inne).

## 1 Pytanie

Mały model językowy ma od 30 do 500 milionów parametrów ( $N$ ). Trenuje się go na pewnej liczbie tokenów; token to kawałek tekstu, średnio około czterech bajtów tekstu polskiego lub angielskiego. Liczbę tokenów podajemy jako wielokrotność  $N$ :  $20N$  to zwykle minimum dla modelu tej wielkości,  $100N$  to długi trening; nasze własne finałowe biegi miały  $200$ – $400N$ . Dla każdej wielkości modelu chcemy trzech liczb: tokenów na sekundę na danej karcie, godzin do końca i ceny.

## 2 Jak mierzyliśmy

**Szybkość.** Mierzymy przepustowość treningu w tokenach na sekundę: medianę z biegu albo z krótkiego benchmarku, jeśli pełnego biegu nie było, z pominięciem chwil, w których model jest oceniany lub zapisywany. Wszystkie liczby pochodzą z naszego kodu treningowego: precyzja bf16, `torch.compile`, kontekst 1 024 tokeny, batch 32 sekwencje. Inny kod da inne liczby.

**Cena.** Korzystamy z publicznego cennika RunPod z 2 października 2026, godz. 12:38 UTC. RunPod ma dwa rodzaje maszyn: *community* (u prywatnych właścicieli, taniej) i *secure* (w centrach danych, drożej). Koszt treningu to

$$\text{USD za miliard tokenów} = \frac{\text{USD za godzinę}}{\text{tokeny na sekundę} \times 3600} \times 10^9.$$

Obejmuje on tylko czas treningu: przygotowanie maszyny, ocena modelu i przestoje nie są wliczone, więc prawdziwy rachunek jest wyższy. Ceny zmieniają się co kilka tygodni; ze wzoru każdy może przeliczyć tabele dla nowych cen.

## 3 Wyniki

Tabela 1 podaje szybkość, koszt miliarda tokenów oraz godziny i koszt do  $20N$  i  $100N$  tokenów dla każdego połączenia modelu i karty, na którym trenowaliśmy.

| model   | karta (procesor serwera) | tokeny/s | USD za 1 mld tokenów | 20N: godz. / USD | 100N: godz. / USD |
|---------|--------------------------|----------|----------------------|------------------|-------------------|
| 31 mln  | RTX 5090 (Ryzen 9950X)   | 363 000  | 0,53                 | 0,5 / 0,3        | 2,4 / 1,7         |
| 31 mln  | RTX 5090 (EPYC 7543)     | 304 000  | 0,63                 | 0,6 / 0,4        | 2,9 / 2,0         |
| 31 mln  | RTX 5090 (Xeon 6530)     | 250 000  | 0,77                 | 0,7 / 0,5        | 3,5 / 2,4         |
| 31 mln  | RTX Pro 6000             | 337 000  | 1,39                 | 0,5 / 0,9        | 2,6 / 4,4         |
| 63 mln  | RTX 5090                 | 222 000  | 0,86                 | 1,6 / 1,1        | 7,9 / 5,4         |
| 123 mln | RTX 5090                 | 140 500  | 1,36                 | 4,9 / 3,4        | 24,3 / 16,8       |
| 248 mln | RTX 5090 (starszy kod)   | 89 400   | 2,14                 | 15,4 / 10,6      | 77 / 53           |
| 253 mln | RTX Pro 6000             | 99 100   | 4,74                 | 14,2 / 23,9      | 71 / 120          |
| 253 mln | 2 × RTX Pro 6000         | 158 600  | 5,92                 | 8,9 / 29,9       | 44 / 150          |

Tabela 1: Szybkość i koszt treningu w cenach community (RTX 5090 0,69 USD/h, RTX Pro 6000 1,69 USD/h za kartę). Ceny secure są wyższe o 43 % dla RTX 5090 i o 24 % dla RTX Pro 6000.

Model 110 mln trenowaliśmy też na własnej karcie Radeon RX 7900 XTX (24 GB, ROCm pod WSL2), starszym skryptem i z kontekstem 512 tokenów: 66 500–72 800 tokenów na sekundę, około połowy tego, co daje RTX 5090 przy modelu podobnej wielkości. Ta karta nie ma ceny za godzinę; kosztuje tylko prąd.

## 4 Co wynika z liczb

1. **Do około 64 mln parametrów szybkość wyznacza procesor serwera.** Ta sama RTX 5090 trenuje nasz model 31 mln z prędkością 363 000, 304 000 albo 250 000 tokenów na sekundę, zależnie od procesora maszyny, w której siedzi. Nasza pętla treningowa w pełni zajmuje jeden rdzeń procesora i przy małym modelu karta na niego czeka. Droższa karta nie pomaga: RTX Pro 6000 jest przy modelu 31 mln tak samo szybka jak RTX 5090, kosztuje 2,45 raza więcej za godzinę i 1,8–2,6 raza więcej za token.
2. **Większe modele lepiej wykorzystują kartę.** Na RTX 5090 praca wykonana w ciągu sekundy rośnie z około 84 do 104 i 133 bilionów operacji na sekundę dla modeli 63 mln, 123 mln i 248 mln (szacunek z liczby parametrów, więc dolne oszacowanie).
3. **Dwie karty są szybsze, nie tańsze.** Dwie karty RTX Pro 6000 trenują model 253 mln 1,6 raza szybciej niż jedna, a każdy token kosztuje o 25 % więcej.
4. **Kompilacja ma znaczenie.** Bez `torch.compile` model 253 mln trenuje się 1,65 raza wolniej, więc ta sama praca kosztuje 1,65 raza więcej.
5. **RTX 5090 jest najtańsza w przeliczeniu na token we wszystkim, co zmierzaliśmy,** od 31 mln do 248 mln parametrów. Dla modeli 248–253 mln porównanie nie jest jeszcze czyste: liczba dla RTX 5090 pochodzi ze starszej wersji naszego kodu.

## 5 Co dostaliśmy za te pieniądze

Nasze własne zakończone biegi, ocenione naszym protokołem (*nasz protokół, nie oficjalny — our protocol, not official*; „eff” to średnia z naszych angielskich testów). Koszt to czas treningu w cenach community z sekcji 2.

| bieg                  | tokeny   | godziny | koszt (USD) | eff   |
|-----------------------|----------|---------|-------------|-------|
| 63 mln, bieg krótszy  | 13,1 mld | 17,8    | 12,3        | 75,81 |
| 63 mln, bieg dłuższy  | 24,9 mld | 33,6    | 23,2        | 76,07 |
| 123 mln, bieg krótszy | 13,1 mld | 26,6    | 18,3        | 75,84 |
| 123 mln, bieg dłuższy | 24,9 mld | 49,2    | 34,0        | 76,94 |

Przy modelu 63 mln dłuższy bieg dał +0,26 punktu za dodatkowe 10,9 USD; przy modelu 123 mln dał +1,10 punktu za 15,7 USD. Większy model lepiej korzysta z dodatkowych danych. Bieg krótszy i dłuższy różnią się też przepisem, więc to obserwacja kosztowa, a nie kontrolowany eksperyment. Model 253 mln wciąż się trenuje (dotąd 19,7 mld tokenów i około 93 USD); jego liczby to *trening w toku, nie wynik (training in progress; not a result)*.

## 6 Czego jeszcze nie wiemy

- Nie mamy pomiarów na RTX 3090, RTX 4090, RTX A6000, L40S, A100 ani H100, ani żadnych z ośmioma kartami. Następna wersja je doda, zmierzone jednym skryptem benchmarku na danych syntetycznych.
- Model 248 mln na RTX 5090 mierzyliśmy starszą wersją naszego kodu; następna wersja powtórzy ten pomiar.
- Ta sama karta różni się o około  $\pm 20\%$  między maszynami (reguła 1). Jedna liczba na kartę to za mało; przy każdym pomiarze podamy procesor serwera.
- Kontener na wynajętej maszynie może widzieć więcej procesorów i pamięci, niż wolno mu użyć: na jednej maszynie z RTX 5090 narzędzia systemowe pokazywały 256 procesorów i 503 GB pamięci, a kontener miał limit 35 procesorów i 71 GB. Plany oparte na większych liczbach zawodzą.