

Ile kosztuje wytrenowanie małego modelu językowego? Szybkość i cena treningu na wynajmowanych i własnych kartach graficznych

Arkadiusz Słota*

2 października 2026 — krótka nota, wersja 1 (tylko pomiary z naszych dotychczasowych
biegów)

Streszczenie

Odpowiadamy na jedno praktyczne pytanie: jeśli chcemy wytrenować model danej wielkości na danej liczbie tokenów, jaką kartę wynająć, ile to potrwa i ile będzie kosztować? Ta pierwsza wersja korzysta tylko z pomiarów z naszych własnych biegów (modele od 31 mln do 253 mln parametrów, na RTX 5090, RTX Pro 6000 i Radeon RX 7900 XTX) oraz z publicznego cennika RunPod z 2 października 2026. Trzy wnioski: przy modelach do około 64 mln parametrów szybkość ogranicza procesor serwera, a nie karta, więc ta sama RTX 5090 daje od 250 000 do 363 000 tokenów na sekundę; RTX 5090 jest najtańsza w przeliczeniu na token we wszystkim, co dotąd zmierzaliśmy (0,53–2,14 USD za miliard tokenów); dwie karty trenują szybciej niż jedna, ale token kosztuje o 25 % więcej. Następna wersja doda karty, których jeszcze nie używaliśmy (RTX 3090, 4090, A100, H100 i inne).

1 Pytanie

Mały model językowy ma od 30 do 500 milionów parametrów (N). Trenuje się go na pewnej liczbie tokenów; token to kawałek tekstu, średnio około czterech bajtów tekstu polskiego lub angielskiego. Liczbę tokenów podajemy jako wielokrotność N : $20N$ to zwykle minimum dla modelu tej wielkości, $100N$ to długi trening; nasze własne finałowe biegi miały 200 – $400N$. Dla każdej wielkości modelu chcemy trzech liczb: tokenów na sekundę na danej karcie, godzin do końca i ceny.

2 Jak mierzyliśmy

Szybkość. Mierzymy przepustowość treningu w tokenach na sekundę: medianę z biegu albo z krótkiego benchmarku, jeśli pełnego biegu nie było, z pominięciem chwil, w których model jest oceniany lub zapisywany. Wszystkie liczby pochodzą z naszego kodu treningowego: precyzja bf16, `torch.compile`, kontekst 1024 tokeny, batch 32 sekwencje. Inny kod da inne liczby.

Cena. Korzystamy z publicznego cennika RunPod z 2 października 2026, godz. 12:38 UTC. RunPod ma dwa rodzaje maszyn: *community* (u prywatnych właścicieli, taniej) i *secure* (w centrach danych, drożej). Koszt treningu to

$$\text{USD za miliard tokenów} = \frac{\text{USD za godzinę}}{\text{tokeny na sekundę} \times 3600} \times 10^9.$$

Obejmuje on tylko czas treningu: przygotowanie maszyny, ocena modelu i przestoje nie są wliczone, więc prawdziwy rachunek jest wyższy. Ceny zmieniają się co kilka tygodni; ze wzoru każdy może przeliczyć tabele dla nowych cen.

*Przygotowane z agentami AI Kolektywu: Hart (pomiary i liczby), Latarnik (szkic), Wartownik (ceny i przegląd), Monter (infrastruktura treningowa).

3 Wyniki

Tabela 1 podaje szybkość, koszt miliarda tokenów oraz godziny i koszt do $20N$ i $100N$ tokenów dla każdego połączenia modelu i karty, na którym trenowaliśmy.

model	karta (procesor serwera)	tokeny/s	USD za 1 mld tokenów	20N: godz. / USD	100N: godz. / USD
31 mln	RTX 5090 (Ryzen 9950X)	363 000	0,53	0,5 / 0,3	2,4 / 1,7
31 mln	RTX 5090 (EPYC 7543)	304 000	0,63	0,6 / 0,4	2,9 / 2,0
31 mln	RTX 5090 (Xeon 6530)	250 000	0,77	0,7 / 0,5	3,5 / 2,4
31 mln	RTX Pro 6000	337 000	1,39	0,5 / 0,9	2,6 / 4,4
63 mln	RTX 5090	222 000	0,86	1,6 / 1,1	7,9 / 5,4
123 mln	RTX 5090	140 500	1,36	4,9 / 3,4	24,3 / 16,8
248 mln	RTX 5090 (starszy kod)	89 400	2,14	15,4 / 10,6	77 / 53
253 mln	RTX Pro 6000	99 100	4,74	14,2 / 23,9	71 / 120
253 mln	2 × RTX Pro 6000	158 600	5,92	8,9 / 29,9	44 / 150

Tabela 1: Szybkość i koszt treningu w cenach community (RTX 5090 0,69 USD/h, RTX Pro 6000 1,69 USD/h za kartę). Ceny secure są wyższe o 43 % dla RTX 5090 i o 24 % dla RTX Pro 6000.

Model 110 mln trenowaliśmy też na własnej karcie Radeon RX 7900 XTX (24 GB, ROCm pod WSL2), starszym skrypcem i z kontekstem 512 tokenów: 66 500–72 800 tokenów na sekundę, około połowy tego, co daje RTX 5090 przy modelu podobnej wielkości. Ta karta nie ma ceny za godzinę; kosztuje tylko prąd.

4 Co wynika z liczb

1. **Do około 64 mln parametrów szybkość wyznacza procesor serwera.** Ta sama RTX 5090 trenuje nasz model 31 mln z prędkością 363 000, 304 000 albo 250 000 tokenów na sekundę, zależnie od procesora maszyny, w której siedzi. Nasza pętla treningowa w pełni zajmuje jeden rdzeń procesora i przy małym modelu karta na niego czeka. Droższa karta nie pomaga: RTX Pro 6000 jest przy modelu 31 mln tak samo szybka jak RTX 5090, kosztuje 2,45 raza więcej za godzinę i 1,8–2,6 raza więcej za token.
2. **Większe modele lepiej wykorzystują kartę.** Na RTX 5090 praca wykonana w ciągu sekundy rośnie z około 84 do 104 i 133 bilionów operacji na sekundę dla modeli 63 mln, 123 mln i 248 mln (szacunek z liczby parametrów, więc dolne oszacowanie).
3. **Dwie karty są szybsze, nie tańsze.** Dwie karty RTX Pro 6000 trenują model 253 mln 1,6 raza szybciej niż jedna, a każdy token kosztuje o 25 % więcej.
4. **Kompilacja ma znaczenie.** Bez `torch.compile` model 253 mln trenuje się 1,65 raza wolniej, więc ta sama praca kosztuje 1,65 raza więcej.
5. **RTX 5090 jest najtańsza w przeliczeniu na token we wszystkich, co zmierzaliśmy,** od 31 mln do 248 mln parametrów. Dla modeli 248–253 mln porównanie nie jest jeszcze czyste: liczba dla RTX 5090 pochodzi ze starszej wersji naszego kodu.

5 Co dostaliśmy za te pieniądze

Nasze własne zakończone biegi, ocenione naszym protokołem (*nasz protokół, nie oficjalny — our protocol, not official*; „eff” to średnia z naszych angielskich testów). Koszt to czas treningu w cenach community z sekcji 2.

bieg	tokeny	godziny	koszt (USD)	eff
63 mln, bieg krótszy	13,1 mld	17,8	12,3	75,81
63 mln, bieg dłuższy	24,9 mld	33,6	23,2	76,07
123 mln, bieg krótszy	13,1 mld	26,6	18,3	75,84
123 mln, bieg dłuższy	24,9 mld	49,2	34,0	76,94

Przy modelu 63 mln dłuższy bieg dał +0,26 punktu za dodatkowe 10,9 USD; przy modelu 123 mln dał +1,10 punktu za 15,7 USD. Większy model lepiej korzysta z dodatkowych danych. Bieg krótszy i dłuższy różnią się też przepisem, więc to obserwacja kosztowa, a nie kontrolowany eksperyment. Model 253 mln wciąż się trenuje (dotąd 19,7 mld tokenów i około 93 USD); jego liczby to *trening w toku, nie wynik (training in progress; not a result)*.

6 Czego jeszcze nie wiemy

- Nie mamy pomiarów na RTX 3090, RTX 4090, RTX A6000, L40S, A100 ani H100, ani żadnych z ośmioma kartami. Następna wersja je doda, zmierzone jednym skryptem benchmarku na danych syntetycznych.
- Model 248 mln na RTX 5090 mierzyliśmy starszą wersją naszego kodu; następna wersja powtórzy ten pomiar.
- Ta sama karta różni się o około $\pm 20\%$ między maszynami (reguła 1). Jedna liczba na kartę to za mało; przy każdym pomiarze podamy procesor serwera.
- Kontener na wynajętej maszynie może widzieć więcej procesorów i pamięci, niż wolno mu użyć: na jednej maszynie z RTX 5090 narzędzia systemowe pokazywały 256 procesorów i 503 GB pamięci, a kontener miał limit 35 procesorów i 71 GB. Plany oparte na większych liczbach zawodzą.

Podziękowania

Hart zebrał pomiary i sprawdził każdą liczbę, Wartownik zrobił zrzut cennika i przejrzał tekst, Monter prowadził maszyny treningowe, a Latarnik napisał szkic.