


Dane modelu Slayer 150 1.01: co wykorzystujemy, co odrzuciliśmy i w jakiej ilości

Arkadiusz Słota, Fabryka AI

Wersja robocza, 7 października 2026 — trening w toku



Rysunek 1: Dopełnienie etapu 2 według źródeł (GB tekstu UTF-8, łącznie 57,45 GB, 11 438 146 dokumentów). Piętnaście publicznych źródeł w przypiętych rewizjach, w proporcjach korpusu bazowego przeskalowanych $\times 1,90$. Pakowanie dodaje ponad te 57,45 GB zamierzone kopie dokumentów *fwe-expansion* podobnych do ARC (8,46 GB). Źródło: manifest budowy b73f45f5.

1 Podsumowanie

Slayer 150 1.01 (139 279 760 parametrów, 17 warstw $\times$ 768, słownik BPE 24 576 tokenów) trenuje na około 24,7 mld tokenów w dwóch etapach (tabela 1). Każdy dokument treningowy występuje raz, z dwoma zamierzonymi wyjątkami opisanymi w rozdziale 3: kopiami dokumentów podobnych do ARC oraz OpenStax powtórzonym czterokrotnie. Nie ma dodatkowych epok: ablacja z powtarzaniem puli przegrała (rozdział 6). Faza wygaszania (ostatnie 20 % kroków) korzysta z tej samej mieszanki co faza stała, ponieważ ablacja z wygaszaniem na tekstach edukacyjnych również przegrała.

Etap	Dane	Tokeny (24k)	Kroki
1	pula ARC-MIX (korpus GoLLeM-v5) po retokenizacji do 24k; pierwsze 6 z 8 odcinków	6 455 623 680	0 $\rightarrow$ 197 010
2	jedna permutacja dokumentów (z ziarnem) z niewykorzystanej części puli i dopełnienia (rozdział 4.3)	18 266 295 978	197 010 $\rightarrow$ 754 453

Tabela 1: Etapy danych treningowych. Paczka: $32 \times 1\,024$ tokeny na krok.

2 Gdzie szukać danych

Co	Miejsce	Przypięcie
Pula ARC-MIX, tokeny 12k	zbiór HF SlayerLab/gollem-ui-mirror, plik arcmix/train.bin	rewizja 486a3af3, SHA e87f594f
Karta przepisu ARC-MIX	HF SlayerLab/gollem-v5-arcmix-9b (tylko karta)	—
Tokenizer 12k	HF SlayerLab/gollem-v5-ckpts, plik tokenizer.json	SHA 37333075
Strumień walidacyjny v5	HF SlayerLab/gollem-v5-ckpts, plik vals/arcmix_val.bin	SHA 8253a108
Źródła dopełnienia	15 źródeł HF / S3 (tabela 4)	przypięte rewizje
Korpus bazowy (proporcje)	HF SlayerLab/minimal-en-corpus-5b	rewizja bb3aec23

Tabela 2: Publiczne lokalizacje. Żaden krok nie wymaga tokenu HF poza dwoma źródłami dopełnienia z ograniczonym dostępem (starcoderdata, tiny-textbooks); token użyto jednorazowo, wyłącznie w środowisku jednego procesu, a potem usunięto.

3 Etap 1: pula ARC-MIX

Pulę zbudowano dla GoLLeM-v5 z tokenizerem 12k; jej treść wykorzystujemy bez zmian (tabela 3). Udziały tokenów w puli: korpus bazowy 57,5 %, rozszerzenie FineWeb-Edu 29,3 %, kopie podobne do ARC 12,0 %, OpenStax 1,5 %. Liczby składników pochodzą sprzed opisanych niżej usunięć, dlatego udziały sumują się do 100,3 %.

Składnik	Źródło	Tokeny (12k)	Uwagi
Korpus bazowy	SlayerLab/minimal-en-corpus-5b@bb3aec23 (15 źródeł)	5 396 605 407	3 968 467 dokumentów
Rozszerzenie FineWeb-Edu	HuggingFaceFW/fineweb-edu, sample-100BT, pierwsze 2 384 000 wierszy	2 756 248 149	3 184 usunięte w dekontaminacji
OpenStax	58 podręczników, CC BY 4.0	140 742 204	$35\,185\,551 \times 4$
Kopie podobne do ARC	dokumenty FineWeb-Edu ocenione funkcją <code>arc_score</code>	1 123 440 072	ocena ≥ 4 : +2 kopie; ocena = 3: +1 kopia

Tabela 3: Skład ARC-MIX.

Po usunięciach pula ma **7 088 917 dokumentów i 9 391 706 576 tokenów** (12k, SHA `ecfd0a40`). Usunęliśmy 5 537 dokumentów: 4 362 w skanie WikiText-2 i ARC (test, walidacja) oraz 1 175 regułą licencji CC BY-NC-SA. Po retokenizacji do 24k (dekodowanie tokenizerem 12k, kodowanie 24k, sprawdzony powrót do tekstu) pula ma **8 615 887 241 tokenów** (SHA `8911b9c5`); zbudowano ją dwukrotnie na dwóch maszynach z tą samą sumą SHA. Na tej puli jeden token 24k niesie o 9,0 % więcej tekstu niż token 12k.

4 Etap 2: dopełnienie

4.1 Reguła

Celem jest około 16,4 mld kolejnych tokenów 24k bez powtórzeń. Zachowujemy **proporcje źródeł korpusu bazowego** (`minimal-en-corpus-5b`) przeskalowane $\times 1,90$, to samo rozszerzenie FineWeb-Edu i tę samą dawkę kopii podobnych do ARC co w ARC-MIX (0,397 wobec 0,398). Źródło niewystarczające daje tyle, ile ma, a brakujące bajty rozkładamy na pozostałe źródła proporcjonalnie do ich kwot. OpenStax nie jest skalowany.

Filtry budowy, w kolejności: pokrycie z którymkolwiek odłożonym zbiorem kontrolnym (rozdział 5.2) $\rightarrow$ duplikat korpusu bazowego $\rightarrow$ duplikat już wykorzystanych plików FineWeb-Edu $\rightarrow$ duplikat wewnątrz nowych danych. Dokumenty krótsze niż 200 znaków są odrzucane. Skróć dokumentu to SHA-256 z jego pierwszych i ostatnich 2 000 znaków. Plik FineWeb-Edu użyty jako zbiór kontrolny (`000_00009`) jest odrzucany po sumie SHA. Wynik budowy: **11 438 146 dokumentów, 57 450 444 352 bajty tekstu** (manifest SHA `b73f45f5`).

4.2 Źródła

Źródło	Repozytorium @ rewizja	Dok.	GB	Udział	Licencja
fwe-expansion	HuggingFaceFW/fineweb-edu@87f09149	4 494 091	21,33	37,1 %	ODC-BY 1.0
fineweb-edu	te same pliki, część w proporcji bazy	1 809 246	8,58	14,9 %	ODC-BY 1.0
dclm-baseline	mlfoundations/dclm-baseline-1.0-parquet@817d6752	1 094 166	6,25	10,9 %	CC BY 4.0
stackexchange	togethercomputer/RedPajama-Data-1T@398f9257	1 468 456	3,48	6,1 %	CC BY-SA (treść)
loc-pd-books	storytracer/LoC-PD-Books@5f1f4ee0	8 491	3,13	5,4 %	CC0
starcoderdata	bigcode/starcoderdata@9fc30b57	637 314	2,92	5,1 %	warunki The Stack (ogr. dostęp)
wikipedia	wikimedia/wikipedia@b04c8d1c (20231101.en)	754 440	2,64	4,6 %	CC BY-SA 3.0 / GFDL
project-gutenberg	manu/project_gutenberg@164853d2	4 063	1,64	2,9 %	domena publiczna w USA
scientific-papers	PMC Open Access, podzbiór do użytku komercyjnego	31 493	1,61	2,8 %	CC0 / CC BY / CC BY-SA
open-web-math	open-web-math/open-web-math@fde8ef8d	194 991	1,55	2,7 %	ODC-BY (wg projektu)
finemath	HuggingFaceTB/finemath@e92b25a6	263 340	1,51	2,6 %	ODC-BY
wildchat	allenai/WildChat-1M@7d6490e4	162 481	1,18	2,0 %	ODC-BY
cc-news	vblagoje/cc_news@81eb2ce0	313 380	0,82	1,4 %	nieznana (wymieniona)
ultrachat	HuggingFaceH4/ultrachat_200k@8049631c	71 990	0,42	0,7 %	MIT
tiny-textbooks	nampdn-ai/tiny-textbooks@1f88d0fe	130 204	0,40	0,7 %	Apache 2.0 (ogr. dostęp)

Tabela 4: Źródła dopełnienia. Pakowanie dodaje ponad te pliki 1 484 830 kopii dokumentów *fwe-expansion* podobnych do ARC (8,46 GB). cc-news i ultrachat są źródłami niewystarczającymi; OpenSubtitles pominięto (rozdział 6).

4.3 Region etapu 2

Dane po punkcie przełączenia to jedna permutacja z ziarnem 20261007 wszystkich dokumentów niewykorzystanych odcinków puli oraz wszystkich dokumentów dopełnienia wraz z kopiami ARC; każdy dokument kończy token końca tekstu. Przy przełączeniu w kroku 197 010 niewykorzystana część puli to 1 777 155 dokumentów i 2 153 971 445 tokenów. Spakowany region ma **18 266 295 978 tokenów** (SHA 8bbd2c6a), o 1,5 % mniej, niż wymagało 762 940 kroków pierwotnego planu, dlatego bieg skrócono do 754 453 kroków (wygaszanie od kroku 603 562) zamiast powtarzać dane. Dopełnienie ma średnio około 4,09 bajta na token, od 3,00 dla kodu do 4,62 dla tiny-textbooks; FineWeb-Edu ma 4,48 (tabela 5). Region zawiera 47 tokenów końca tekstu więcej niż jednostek, ponieważ kilka dokumentów ma znacznik końca tekstu dosłownie w treści; nie zmienia to treningu, ale granice jednostek trzeba brać z indeksu pakowania, a nie z tokenów końca tekstu.

Źródło	Jednostki	w tym kopie ARC	Tokeny (24k)	Udział
fwe-expansion	5 962 385	1 480 815	6 647 665 150	36,4 %
pula (niewykorzystane odcinki)	1 777 155	—	2 153 971 445	11,8 %
fineweb-edu	1 804 284	—	1 916 743 396	10,5 %
dclm-baseline	1 088 455	—	1 499 403 178	8,2 %
stackexchange	1 468 446	—	1 036 377 059	5,7 %
starcoderdata	637 310	—	974 144 383	5,3 %
loc-pd-books	8 477	—	933 188 923	5,1 %
wikipedia	752 475	—	664 931 978	3,6 %
finemath	262 926	—	455 661 822	2,5 %
scientific-papers	31 491	—	448 862 907	2,5 %
project-gutenberg	4 050	—	434 101 961	2,4 %
open-web-math	194 863	—	430 112 118	2,4 %
wildchat	162 462	—	297 434 703	1,6 %
cc-news	313 374	—	195 910 044	1,1 %
ultrachat	71 981	—	92 174 421	0,5 %
tiny-textbooks	130 174	—	85 612 490	0,5 %
Region	14 670 308	1 480 815	18 266 295 978	100 %

Tabela 5: Region etapu 2 według źródeł, po skanach (manifest pakowania; jednostka to dokument albo kopia ARC, każda zakończona tokenem końca tekstu). Prefiks regionu o długości danych ablacji (2 mld tokenów) ma udział puli 11,70 % wobec 11,79 % w całym regionie.

5 Kontrola kontaminacji i zbiory odłożone

5.1 Skany dopełnienia

Skan	Reguła	Wycięte wiersze
WikiText-2 i ARC-Easy/Challenge (test, walidacja)	dowolny wspólny znormalizowany 13-gram; pytania ARC o długości 6–12 słów dopasowywane dokładnie	4 367
Odłożone zbiory kontrolne (rozdział 5.2)	≥ 10 różnych 13-gramów wspólnych z jednym dokumentem kontrolnym	21 765
BLiMP	zdania o długości ≥ 6 słów	0
Suma (unia)	wycięty wiersz usuwany jest razem ze wszystkimi swoimi kopiami ARC	25 808 (0,23 %)

Tabela 6: Skany przed pakowaniem. Najwięcej wycięć: fwe-expansion 12 521, dclm-baseline 5 711, fineweb-edu 4 962, wikipedia 1 965.

5.2 Odłożone osie ewaluacyjne

- **Oś DCLM:** 3 457 dokumentów z `allenai/DataDecide-data-recipes@3baf34ba`, przepis `v0_fw_top3p`, część `part-00-00000` (SHA `ff7cecf4`); 1 543 z 5 000 odrzucone za pokrycie z dowolnym wycinkiem treningowym lub testami tablicy.
- **Oś FineWeb-Edu:** 3 507 dokumentów z `sample/100BT/000_00009` (SHA `1b9f68e5`); 1 493 z 5 000 odrzucone za pokrycie 13-gramowe lub adresem URL.

Obie osie mierzymy w bitach na bajt, co pozwala uczciwie porównywać różne tokenizery.

6 Rozważone i odrzucone

Opcja	Dlaczego nie	Dowód
Powtarzanie puli (~2,65 epoki)	przeigrana w ablacji	ablacja 64M (b)
100 % FineWeb-Edu	lepsze tylko we własnej domenie: FWE $-0,016$ bpb, DCLM $+0,089$ bpb	ablacja 64M (e)
Wygazanie na tekstach FineWeb-Edu	DCLM $+0,0505$ bpb, wynik tablicy $+0,07$ (szum)	H2, cztery biegi
Tokenizer 12k	$+0,0045$ bpb przy równej liczbie parametrów	ablacja (h)
Tokenizer 32k	nie lepszy od 24k ($+0,0014$ / $+0,0017$ bpb)	ablacja (h)
Tokenizer SmolLM2 49k	jeszcze nieporównany ; planowana ablacja (t)	—
QC-FineWeb top 3 %	ten sam rozkład co oś kontrolna DCLM; niejasna licencja	decyzja z 6 października
arXiv	odrzucony we wcześniejszym przeglądzie korpusu (25 września)	—
PubMed poza komercyjnym PMC	licencje na poziomie artykułu	użyto PMC OA (komercyjny)
OpenSubtitles	dostępny tylko plik angielski o rozmiarze 6,7 MB	pominięty
Jeden zakres URL	Windows Defender oznaczył	wykluczony po nazwie
StackExchange	Trojan:HTML/ScrInject	
Dokumenty CC BY-NC-SA	licencja niekomercyjna	usunięte (1 175)

Tabela 7: Opcje rozważone i odrzucone. Ablacje to modele 64M trenowane na 2 mld tokenów; bpb mierzone na odłożonych osiach z rozdziału 5.2 (wartość ujemna oznacza poprawę).

7 Tokenizery

Tokenizer	SHA	Uwagi
12k (v5)	37333075	słownik 12 288
24k (Slayer 150 1.01)	afeb22b4	BPE na poziomie bajtów, słownik 24 576; trenowany na 1,0 GB angielskiego tekstu z puli (205 522 dokumenty); 4,021 bajta na token na odłożonym tekście angielskim, bez błędów odtworzenia tekstu
32k	30be1bba	ten sam trener i próbka; 4,126 bajta na token

Tabela 8: Tokenizery.

8 Odtwarzalność

Każdy artefakt jest przypięty sumą SHA-256. Artefakty puli (pula 12k, pula 24k, kolejka etapu 1) zbudowano bit w bit na co najmniej dwóch maszynach, a plik źródłowy weryfikowano po każdym pobraniu. Dopelnienie zbudowano raz i sprawdza się je plik po pliku względem manifestu. Tokenizację dopelnienia sprawdzono na dwóch maszynach: ten sam plik daje ten sam strumień tokenów (tę samą sumę SHA).

Artefakt	SHA-256 (prefiks)
ARC-MIX, plik źródłowy (12k)	e87f594f
Pula ARC-MIX (12k)	ecfd0a40
Pula 24k	8911b9c5
Kolejka etapu 1 (8 odcinków $\times$ 32 835 kroków)	c60d76c9
Plan pobrania / manifest pobrania / źródła	5817b464 / 6a480f54 / 38489e4e
Manifest budowy dopełnienia	b73f45f5
Listy wycięc ze skanów (argumenty pakowania)	baa6a4af
Kod pakowania	3976d146

Tabela 9: Artefakty i prefiksy ich sum SHA-256.

9 Kwestie otwarte

- Licencje do potwierdzenia przed kartą modelu: open-web-math, StackExchange (treść CC BY-SA), Project Gutenberg (domena publiczna w USA), cc-news (nieznana, wymieniona wprost).
- Test mieszanki (g) na prefiksie regionu o długości 2 mld tokenów (SHA cf67e423) wobec kontroli 24k, z regułą nie-gorszości zapisaną przed biegiem.