


Slayer 150 1.01: wybór przepisu treningu przy regułach ustalanych przed każdym wynikiem

Arkadiusz Słota, Fabryka AI

Wersja robocza, 7 października 2026 — trening w toku



Rysunek 1: Dziewięć ablacji (64M parametrów, 2 mld tokenów) ocenianych regułami zapisanymi przed każdym wynikiem. Słupki pokazują zmianę liczby bitów na bajt na zbiorze kontrolnym w stylu DCLM wobec punktu odniesienia danego wariantu; linia przerywana to próg przyjęcia $-0,006$. Przekroczył go tylko słownik 24k (d). Słupki (e) i H2 są ucięte na $+0,0115$; prawdziwe wartości to $+0,0888$ i $+0,0505$. Wartości z plików werdyktów wymienionych w `recipe/`.

Streszczenie

Opisujemy, jak wybrano przepis treningu modelu Slayer 150 1.01, czyli anglojęzycznego modelu bazowego o 139,3 mln parametrów, przygotowanego na tablicę wyników Glint Tiny-ML. Każdą zmianę przepisu najpierw sprawdzano w ablacji: na modelu 64M trenowanym na 2 mld tokenów. Zmianę przyjmowano albo odrzucano według reguły zapisanej, zanim wynik był znany. Każdą regułę zaimplementowano dwukrotnie, niezależnie, a obie implementacje porównano ze sobą na syntetycznych siatkach przypadków przed użyciem. Z dziewięciu ablacji jedna została przyjęta (słownik 24k zamiast 12k), pięć odrzucono, a trzy były nierozstrzygnięte albo pozostawiły ustawienie domyślne (rysunek 1). Przepis finalny to zmierzony przepis bazowy przeskalowany do 139,3 mln parametrów, ze słownikiem 24k, harmonogramem WSD (rozgrzewka, faza stała, wygaszanie) z wygaszaniem na ostatnich 20 % kroków i około 24,7 mld unikalnych tokenów. Opisujemy też problem pomiarowy samej tablicy: po ponownej ocenie czołowych modeli jedną, wspólną procedurą 11 z 12 wpisów wypada niżej niż liczby zgłoszone przez autorów, a wynik ogólny modelu z pierwszego miejsca spada z 79,67 do 76,33. Trening finalny trwa; jego wyniki zostaną dodane w kolejnej wersji.

1 Cel i ograniczenia

- **Cel:** pierwsze miejsce na publicznej tablicy Glint Tiny-ML w wyniku ogólnym ($Overall = (BLiMP + ARC-Easy + WikiScore)/3$) albo w wyniku ważonym rozmiarem modelu (eff). Przy naszym rozmiarze łatwiejszy jest wynik ogólny (próg 79,67 wobec około 80,2 dla eff).
- **Budżet:** jedna wynajmowana karta RTX 5090 (około 1 USD za godzinę), około 55–60 godzin pracy karty na trening finalny.
- **Limit rozmiaru:** poniżej 150 mln parametrów. Model finalny ma 139 279 760 parametrów (współdzielona macierz osadzeń liczona raz).

2 Metoda: najpierw reguła, potem wynik

Skala ablacji. Wszystkie ablacje to modele 64M trenowane na 2 mld tokenów (61 035 kroków), z tą samą kolejnością danych. Wszystkie warianty trenowano na tej samej klasie karty (RTX 5090), a oceniano na jednej karcie RTX 3090.

Osie decyzyjne. Główną miarą są bity na bajt (bpb) na dwóch zamrożonych, odłożonych zbiorach kontrolnych: ogólnym zbiorze tekstów z sieci (w stylu DCLM) i zbiorze edukacyjnym (FineWeb-Edu, FWE). Bity na bajt nie zależą od tokenizera, więc modele z różnymi słownikami porównujemy uczciwie. Wynik tablicy (eff) raportujemy i używamy wyłącznie jako warunku bezpieczeństwa, bo w tej skali jest zaszumiony (odchylenie standardowe różnicy dwóch ziaren losowych wynosi około 0,61 eff).

Model szumu. Szum między ziarnami losowymi szacujemy z trzech przebiegów bazowych i przyjmujemy dolną granicę $\sigma = 0,002$ bpb. Aby różnica wobec średniej trzech przebiegów bazowych liczyła się jako poprawa, musi wynieść co najmniej $-0,006$ bpb (około 2,1–2,6 odchylenia standardowego różnicy): na osi głównej (DCLM) dla wariantów (a)–(d) i na obu osiach dla (e) i (h). Spadek eff nie może przekroczyć 0,56.

Najpierw reguła. Dla każdej ablacji regułę przyjęcia, punkt odniesienia i dane zapisywano w dzienniku decyzji przed startem treningu. Jeśli regułę trzeba było zmienić, zmiana następowała przed jakimkolwiek wynikiem, a jej powód był zapisywany (punkt 6).

Dwie implementacje. Każdą regułę zaprogramowały dwie osoby, niezależnie od siebie. Przed każdym werdyktem obie implementacje porównano na syntetycznych siatkach przypadków,

obejmujących dokładne wartości graniczne: zgodność 360/360 dla ablacji (a)–(e), 180/180 dla (h), 48/48 dla H2 i 108/108 dla (k). Siatka dla obecnej wersji reguły „nie gorzej” (g) jest w przygotowaniu. Każdy werdykt liczyły obie implementacje i musiały dać ten sam wynik.

Kontrola powtarzalności oceny. Zanim zaufaliśmy zmienionemu łańcuchowi oceny, ponownie oceniliśmy już oceniony punkt kontrolny i wymagaliśmy podsumowania identycznego co do bitu (trzy takie kontrole, wszystkie zaliczone).

3 Ablacje (64M, 2 mld tokenów)

Tabela 1 podaje różnice w bpb na dwóch zbiorach kontrolnych (ujemne = lepiej) i w eff (dodatnie = lepiej).

Wariant	Zmiana	Δ DCLM	Δ FWE	Δ eff	Werdykt
(a)	kształt 18×512 zamiast 14×576, hiperparametry bazowe	+0,0038	+0,0036	−0,81	odrzucone
(b)	0,755 mld unikalnych tokenów powtórzonych około 2,65 raza (ten sam budżet)	+0,0051	+0,0052	−0,12	odrzucone
(c)	harmonogram WSD (20 % wygaszania) zamiast kosinusowego	−0,0057	−0,0054	−0,24	nierozstrzygnięte; przyjęte jako zmiana bezkosztowa
(d)	słownik 24k zamiast 12k	−0,0101	−0,0100	+0,61	przyjęte
(e)	100 % FineWeb-Edu	+0,0888	−0,0161	+0,19	nierozstrzygnięte (wygrywa tylko we własnej domenie)
(h12)	słownik 12k + 2 warstwy, równa liczba parametrów, wobec (d)	+0,0045	+0,0045	−1,33	odrzucone
(h32)	słownik 32k − 1 warstwa, równa liczba parametrów, wobec (d)	+0,0014	+0,0017	+0,34	odrzucone; zostaje 24k
H2	wygaszanie na 100 % FineWeb-Edu, wobec średniej 3 kontroli	+0,0505	−0,0091	+0,07	odrzucone
(k) 0,1	wygaszanie 10 % wobec 20 %	+0,0018	+0,0020	−0,38	zostaje 20 %
(k) 0,3	wygaszanie 30 % wobec 20 %	−0,00001	−0,0002	+0,12	zostaje 20 %

Tabela 1: Werdykty ablacji. Każdą regułę zapisano przed treningiem; każdy werdykt policzyły dwie niezależne implementacje.

Zakres wniosków:

- **(a)** odrzuca kształt 18×512 *przy bazowym współczynniku uczenia i rozgrzewce*, a nie głębokość w ogóle.
- **(d)** porównuje równe liczby tokenów, a nie bajtów. W naszej puli danych token słownika 24k niesie o około 9,0 % więcej tekstu niż token 12k (ta sama pula to 9,39 mld tokenów w 12k i 8,62 mld w 24k), więc część zysku to „więcej tekstu za ten sam budżet tokenów”. **(h)** usuwa wpływ liczby parametrów: przy równej liczbie parametrów słownik 12k z większą liczbą warstw wypada gorzej, a 32k z mniejszą liczbą warstw nie wypada lepiej.
- **(h32)** ma nieco wyższy wynik tablicy (+0,34 eff, +0,97 ARC-Easy), ale gorsze bpb na obu osiach. Obie różnice mieszczą się w szumie; rozstrzygnęła reguła zapisana przed treningiem, oparta na bpb.

- **H2** sprawdzało, czy kończenie treningu na tekstach edukacyjnych pomaga w tablicy. Przesuwa model w stronę BLiMP i FineWeb-Edu, pogarsza ogólny tekst z sieci i Wikipedię (perpleksja bajtowa +0,095) i nie zmienia wyniku tablicy. Przebiegi kontrolne H2 zmierzyły też szum samej fazy wygaszania: $\sigma_{\text{par}} = 0,00028$ bpb (DCLM), czyli około czterokrotnie mniej niż szum między ziarnami.

4 Przepis finalny

Ustawienie	Wartość
Kształt	17 warstw $\times$ 768, 12 głów uwagi (proporcje bazowe przeskalowane)
Słownik	24 576 tokenów, bajtowy BPE wytrenowany na naszej puli; 4,02 bajta na token na odłożonym tekście angielskim; bezstratne odtworzenie tekstu
Parametry	139 279 760 (osadzenia 18,9 mln)
Trener	trener referencyjny na jedną kartę; Muon dla wag dwuwymiarowych, AdamW dla pozostałych
Partia, kontekst	32×1024 tokeny na krok
Harmonogram	WSD, wygaszanie na ostatnich 20 % kroków
Tokeny	około 24,7 mld (754 453 kroki; trening skrócony do liczby dostępnych unikalnych tokenów), bez dodatkowych epok; wewnętrzne powtórzenia samej puli (kopie dokumentów związanych z ARC, 12,0 % puli, i OpenStax $\times 4$, 1,5 %) są częścią zmierzonego przepisu
Dane	zmierzona mieszanka bazowa (8,6 mld tokenów) dopełniona z tych samych źródeł w przybliżeniu w tych samych proporcjach (krótsze źródła rozłożone na pozostałe; praca towarzysząca)
Kolejność danych	stała kolejka slotów z zapisanymi skrótami SHA-256; wznawianie tylko na granicach slotów

Tabela 2: Przepis treningu finalnego.

Dlaczego nie stroiliśmy mieszanki. Ablacja (e) pokazała, że zmiana udziału tekstów edukacyjnych daje duże efekty, różne na różnych osiach, więc nie ekstrapolowaliśmy nowej mieszanki z dwóch punktów. Dopełnienie zachowuje proporcje bazowe. Zanim dopełnione dane wejdą do treningu, muszą przejść zapisany z góry **test „nie gorzej” (g)**: model 64M trenowany na losowej próbce 2 mld tokenów *dokładnie tej* mieszanki finalnej nie może być gorszy od modelu kontrolnego ze słownikiem 24k o więcej niż +0,006 bpb na żadnej z osi ani o więcej niż 0,99 eff. Jeśli test nie przejdzie albo się spóźni, trening kończy się na samej puli bazowej (plan B), z wygaszaniem na tej puli. Moment przełączenia ustalamy z góry razem z mieszanką, więc test zawsze mierzy dokładnie tę mieszankę, którą zobaczy trening.

Mieszanie na poziomie dokumentów. W chwili wejścia dopełnienia niewykorzystana część puli bazowej i nowe dane są mieszane w jednej permutacji całych dokumentów. Faza wygaszania widzi więc tę samą mieszankę, którą zmierzył test (g), a nie naprzemienne bloki starych i nowych danych.

Długość treningu wynika z danych. Dopełnienie daje 4,09 bajta na token zamiast planowanych 4,0, więc trening skrócono do liczby dostępnych unikalnych tokenów (około 24,7 mld, 754 453 kroki zamiast 762 940), zamiast powtarzać dane; wygaszanie zachowuje udział 20 % nowej długości.

5 Fakty inżynierskie, od których zależy przepis

- **Przepustowość** na jednej karcie RTX 5090 przy partii 32 (ta sama sonda dla wszystkich kształtów): 108,6 mln $\rightarrow$ 156 720 tokenów/s; 122,8 mln $\rightarrow$ 136 250; 144,0 mln (12k) $\rightarrow$

117 290; **139,3 mln (24k) → 124 798**. Przy tej wielkości kształt 24k (139,3 mln) jest o 6,4% szybszy niż kształt 12k (144,0 mln). Trwający trening finalny utrzymuje 117–121 tys. tokenów/s; powolny spadek wynika z limitu mocy karty.

- **Wznowienie jest dokładne na tej samej klasie karty.** Wznowienie fazy wygaszania z punktu kontrolnego na innej karcie RTX 5090 odtworzyło pierwotny przebieg z dokładnością $3 \cdot 10^{-7}$ bpb (DCLM) i $4 \cdot 10^{-6}$ bpb (FineWeb-Edu). Przejście na trening na wielu kartach poprzedza test równoważności z progami ustalonymi z góry.
- **Tożsamość danych sprawdzamy skrótami, a nie opisem procedury.** Każde odtworzenie puli na nowej maszynie dało ten sam plik co do bitu. Tokenizacja dopełnienia dała identyczne bajty na dwóch różnych maszynach i systemach operacyjnych na pliku testowym; tożsamość całego zmieszanego regionu jest sprawdzana skrótem przed użyciem.
- **Dekontaminacja** dopełnienia względem WikiText-2, ARC (zbiory testowe i walidacyjne) i BLiMP oraz usunięcie nakładania z naszymi zbiorami kontrolnymi usunęły 25 808 z 11,4 mln dokumentów (praca towarzysząca).

6 Co poszło nie tak i co poprawiliśmy przed wynikami

- Pierwszy margines bezpieczeństwa dla eff w teście „nie gorzej” ($-0,495$) wynosił jedno odchylenie standardowe, przez co dobra mieszanka byłaby odrzucana w około 16% przypadków. Przed jakimkolwiek wynikiem (g) poszerzyliśmy go do $-0,99$.
- Pierwsza reguła H2 opierała się na jednej, zaszumionej parze przebiegów; symulacja pokazała do 8,6% fałszywych przyjęć. Przed pierwszym przebiegiem H2 zastąpiliśmy ją regułą z trzema przebiegami kontrolnymi i dokładnie 5% fałszywych przyjęć.
- Pierwsza propozycja reguły (k) miała jeden warunek: $\Delta\text{DCLM} \leq -0,002$ (jedno σ między ziarnami). Wobec znanego wtedy szumu to około 0,7 odchylenia standardowego różnicy dwóch przebiegów, czyli w przybliżeniu normalnym około 24% fałszywych zmian na wariant. Przed (k) przebudowaliśmy regułę: $\Delta\text{DCLM} \leq -\max(0,002; t\sigma_{\text{par}}\sqrt{2})$, gdzie σ_{par} zmierzono na fazie wygaszania, plus $\Delta\text{FWE} \leq 0$ i warunek bezpieczeństwa dla eff. Zmierzony szum wygaszania ($\sigma_{\text{par}} = 0,00028$) okazał się mały, więc wiąże dolna granica 0,002, a próg to około pięciu odchyłeń standardowych różnicy dwóch wygaszeń.
- Test „nie gorzej” (g) pierwotnie porównywał wynik z przebiegami bazowymi ze słownikiem 12k; wtedy zysk ze słownika przepuściłby dowolną mieszankę. Przed testem zmieniliśmy punkt odniesienia na model ze słownikiem 24k.

7 Problem pomiarowy tablicy wyników

Tablica podaje liczby zgłoszone przez autorów, z których każda została zmierzona ich własną procedurą oceny. Przy jednej, wspólnej procedurze (dodatek A) nasza ponowna ocena czołowych wpisów daje tabelę 3.

Model	Zgłoszony wynik ogólny	Wynik ogólny po ponownej ocenie (wspólna procedura)
Haidass-143M	79,67	76,33 (ARC-Easy 56,23 wobec zgłoszonych 60,23)
GPT-X2-125M	79,45	77,67
GoLLeM-v5 128M (nasz)	—	76,30

Tabela 3: Zgłoszony i ponownie oceniony wynik ogólny czołowych wpisów.

Przy wspólnej procedurze 11 z 12 ponownie ocenionych wpisów wypada niżej niż zgłoszone liczby, a kolejność się zmienia: pierwsze miejsce ma GPT-X2 z wynikiem 77,67, a nasz poprzedni model traci do Haidass 0,03 punktu. Najbardziej prawdopodobnym wyjaśnieniem są różnice między procedurami oceny (format promptu, normalizacja, ustawienia few-shot); nie twierdzimy, że którakolwiek zgłoszona liczba jest błędna w ramach własnej procedury. Wielkość tego efektu zależy też od modelu (nasz v5 zyskuje +1,05 w lm-eval 0.4.13, inny model +2,61), więc liczb z różnych procedur nie da się przeliczyć stałą. Model finalny przedstawimy w obu wersjach: w lm-eval 0.4.13 na wersjach zbiorów ustalonych przez ewaluator Fabryka track oraz we wspólnej procedurze, obok ponownie ocenionych wpisów.

8 Stan prac i ograniczenia

- Trening finalny trwa. Żaden jego punkt kontrolny nie jest podstawą decyzji poza twardymi awariami (NaN, skoki straty, gwałtowny wzrost normy gradientu), a żadnego wyniku pośredniego nie porównujemy z progiem tablicy. Ze względu na zmianę dostawcy mocy obliczeniowej trening zostanie wznowiony od ustalonego punktu kontrolnego na granicy slotu na nowej maszynie; dopełnienie (jeśli test (g) przejdzie) wchodzi w tym samym punkcie.
- Wszystkie ablacje mają 64M parametrów i 2 mld tokenów; model finalny ma 139M parametrów i około 24,7 mld tokenów. Kierunki efektów przenoszą się pewnie niż ich wielkości.
- Jedno ziarno losowe na wariant ablacji ($n = 1$), z odpowiednio dobranymi progami.
- Gotowego tokenizera 49k (SmolLM2) jeszcze nie porównaliśmy; test jest zaprojektowany (dwa warianty, które obejmują skalę docelową z obu stron) i jego wynik podamy w kolejnej wersji.

A Wspólna procedura oceny

- **Wynik:** Overall = (dokładność BLiMP + dokładność ARC-Easy + WikiScore)/3, gdzie WikiScore przekształca perplexję bajtową na WikiText-2 na skalę 0–100 w skali logarytmicznej, tak jak na tablicy.
- **Zbiory (ustalone wersje):** EleutherAI/wikitext_document_level @6472347, nyu-ml1/blimp @877fba0, allenai/ai2_arc (ARC-Easy, test) @210d026.
- **Ocena ARC-Easy:** logarytm prawdopodobieństwa odpowiedzi przy danym pytaniu, bez normalizacji długości (acc), tak jak na tablicy.
- **Narzędzia:** nasz wspólny kod oceny oraz lm-eval 0.4.13 dla liczb w formacie tablicy. Skróty skryptów i pliki wyników dla każdego modelu są wymienione w katalogu `recipe/` tego wydania.