Slayer 1.07: dane i sposób treningu

Co model ma umieć, jakie dane i dlaczego, jak trenujemy

Arkadiusz Słota
SlayerLab

2 listopada 2026, wersja robocza v0.4.6 — do decyzji zespołu treningowego

Streszczenie. Przedstawiamy zbiór danych i projekt dalszego pretreningu modelu Slayer o ok. 1,07 mld parametrów. Punkt startowy, Slayer 1.06, zużył 14 520 680 448 tokenów w 13 848 krokach. Przygotowany zbiór 1.07 zawiera 8 891 005 707 tokenów w 9 plikach, zakodowanych tokenizerem Slayera; obejmuje polski web, angielskie teksty edukacyjne i matematyczne oraz powtórkę polskiego rdzenia i prawa. Opisujemy maskowanie danych osobowych, usuwanie dokumentów zawierających fragmenty testów oraz kontrolę zgodności tokenów ze źródłem. Po recenzji rozdzielamy poprawę końcowego modelu od przyczynowego efektu nowych danych: kontrola obejmuje tylko wspólny odcinek 150 kroków i dostępne wyniki ramienia odniesienia. Protokół oddziela wybór checkpointu od oceny, traktuje trafność liter jako diagnostykę i uwzględnia szum checkpointów oraz wielokrotne porównania. W zakończonej krótkiej sondzie wstawka formatu nie usunęła dominacji litery. Wstawka dziedzinowa spełniła kryterium ruchu BPB poprawnej odpowiedzi w dół, ale taki ruch objął również kontrolę. Nie potwierdzono przewidywanej swoistości dziedzinowej; nie utożsamiamy tego z brakiem efektu wstawki. Trening etapu 1.07 nie został wykonany. Dobór dalszych źródeł, konfiguracja wydania i uruchomienie pozostają decyzjami zespołu treningowego. Dokument nie przedstawia wyników modelu 1.07.

1 Cel: co Slayer ma umieć

Założenia projektu.

- **Objętość:** minimum 40 mld tokenów treningu dla modelu 1B, docelowo 100 mld. Przygotowany etap 1.07 obejmuje 8 891 005 707 tokenów, w tym 1 894 295 941 tokenów celowej powtórki polskich danych 1.06. Nie utożsamiamy liczby ekspozycji treningowych z objętością unikalnych tekstów. Termin i konfigurację biegu wybiera zespół treningowy po przeglądzie danych i niniejszego dokumentu.
- **Języki:** Slayer zaczął od polskiego. Dalsze dane mogą mieć więcej angielskiego, ale nie na siłę: udział EN wynika z tego, że polskiego tekstu jest dużo mniej niż angielskiego.
- **Umiejętności:** model ma się uczyć umiejętności, także metodami, które działały gdzie indziej. Metodę przyjmujemy dopiero wtedy, gdy ma dowód w literaturze albo w naszym pomiarze (sekcja 6).

Punkt wyjścia: Slayer 1.06. Zrealizowany skład plików danych 1.06 według manifestów: web 53,9 %, rdzeń 18,6 %, prawo 9,2 %, EN 18,2 %. Nie są to docelowe wagi próbkowania 63/19/8/10 z karty zbioru. Suma treści plików wynosi 14 524 133 431 tokenów, natomiast liczba tokenów zużytych w treningu to $13\,848 \times 1\,048\,576 = 14\,520\,680\,448$. Daje to ok. 13,5 tokenu na parametr. Wartość ok. 20 tokenów na parametr jest odniesieniem do budżetu obliczeń, a nie gwarantowanym progiem osiągnięcia umiejętności. Obserwacje dla 1.06 opisuje sekcja 2. W skrócie:

1. w badanych protokołach pytań wielokrotnego wyboru Slayer wybiera jedną literę w 83–94 % pytań; sama trafność liter nie oddziela preferencji formatu od umiejętności;
2. na pytania o krótką odpowiedź odpowiada pełnym zdaniem, więc dokładne dopasowanie daje prawie 0 (0,005 na NQ i 0,015 na TriviaQA na panelu 200);
3. po kalibracji preferencji litery pozostaje blisko poziomu losowego na MMLU i MedMCQA; zgodne z tym są co najmniej dwie hipotezy: niedostateczne dane dziedzinowe albo niedotrenowanie, których ten wynik nie rozdziela;
4. polskiej wiedzy dziedzinowej (podręcznikowej) jest w danych mało.

Co 1.07 ma poprawić, w kolejności ważności.

1. **Wiedza (PL i EN):** sprawdzić, czy dalszy trening na tekstach edukacyjnych i dziedzinowych poprawia zadania poza treningiem (sekcja 3). Rodzinę werdyktu i metryki określa sekcja 9; trafność z liter i BPB poprawnej odpowiedzi pozostają diagnostyką, nie samodzielnym dowodem przyrostu wiedzy.
2. **Utrzymanie polskiego:** przy większym udziale EN polski nie może się pogorszyć ponad szum. Miary: heldout PL, MultiBLiMP-PL, ARC-Easy-PL. Spadek ponad szum to koszt, który raportujemy wprost (sekcja 9).
3. **Format odpowiedzi:** oddzielnie zmierzyć literę A–D i krótką odpowiedź. Dane F/K nie są częścią przygotowanego zbioru 1.07. Zakończona sonda rozdziela sukces ruchu BPB od potwierdzenia swoistości dziedzinowej; jej wyniki i ograniczenia opisuje sekcja 7. Decyzja o dodatkach pozostaje po stronie zespołu treningowego.

Czego ten dokument nie obiecuje. Wielkości zysków to hipotezy zapisane przed treningiem, a nie wyniki. Zadania, w których na naszym panelu 200 pozycji zgadują i Slayer, i LFM2.5, mają niski priorytet przy obecnym budżecie. Nie dowodzi to jednak, że danymi nie da się ich poprawić. Zadania z przeciekiem źródeł testu do danych treningowych nie wchodzą do wniosków (sekcja 4).

2 Stan wyjściowy: zmierzone mankamenty Slayera 1.06

Punkt odniesienia to Slayer 1.06 w kroku 13 848. Model porównawczy tej samej skali to LFM2.5-1.2B-Base. Liczby pochodzą z panelu bench50 (po 200 pozycji na zadanie, `results.json` Space `1cf2b8bb`) i z zapisanych wyników per pozycja. Wynik uznajemy za odróżnialny od zgadywania, gdy dolna granica CI95 przekracza max(poziom losowy, udział klasy większościowej). Dla zadań z podzbiorami (MMLU, BLiMP, BBH) CI liczymy bootstrapem Rao–Wu.

Tabela 1: Zadania bench50 według odróżnialności od zgadywania (panel $n = 200$).

klasa	zadań	przykłady
Slayer na poziomie losowym, LFM2.5 ponad	8	ARC-C, WinoGrande, SST-2, PolEmo2-in, MMLU, RACE, MedMCQA, PAWS
oba modele na poziomie losowym	13	BoolQ, CB, WiC, RTE, ANLI-r3, PROST, Belebele-PL, PPC, PSC, CBD, KLEJ-NER, LLMzSzŁ, CoLA
oba ponad poziomem losowym	8	BLiMP, MultiBLiMP-PL, HellaSwag, OpenBookQA, SciQ, COPA, 8tags, DYK
bez bazy losowej lub bez wyniku	21	generacja, perpleksja

1. Format liter. W pytaniach A–D Slayer 1.06 wybiera najczęstszą literę w 83–94 % odpowiedzi, a Pythia-1B w 84,4–96,0 %. Trafności obu modeli z liter różnią się tylko o szum (repozytorium benchmarks-fabryka-ai, `research/analyses/answer-format`). Na LLMzSzŁ Slayer wybiera B w 66 % pytań (pomiar wewnętrzny). Wynik MMLU, MedMCQA i Belebele-PL liczony z liter traktujemy więc jako artefakt formatu, a nie jako miarę wiedzy. Po treści odpowiedzi (cloze, ARC-C acc_norm, wyniki sparowane) cały przyrost między wersjami przypada na odcinek 1.00→1.03: +3,84 pkt, $z = 2{,}19$. Odcinek 1.03→1.06, czyli ok. 7 mld tokenów, daje +0,17 pkt, $z = 0{,}09$, czyli szum (to samo źródło). Wynik 1.06, 0,2577, leży poniżej bazy większościowej 0,265.

2. Wiedza po odjęciu formatu. Po odjęciu priorytetu litery (kalibracja leave-one-out, bez etykiet; pomiar wewnętrzny) udział najczęstszej litery spada do 27–36 %, ale trafność na MMLU, MedMCQA, LLMzSzŁ i Belebele-PL zostaje na poziomie losowym. Sam format nie odsłania więc ukrytej wiedzy. Mamy dwa wyjaśnienia i 1.07 ich nie rozdziela: *brak wiedzy dziedzinowej w danych* albo *niedotrenowanie* (1.06 to ok. 14,5 mld tokenów bez wygaszania LR). Pythia-1B po 300 mld tokenów, czyli ok. 20 razy więcej, ma MMLU z liter 0,231 i ARC-C z liter 0,229, a więc też poziom losowy (`results/LICZBY.json` tego samego repozytorium). Poziom losowy modelu 1B na tych zadaniach jest więc typowy przy budżecie rzędu setek mld tokenów i sam nie wskazuje, czego brakuje.

3. Krótka odpowiedź. Na NQ-Open i TriviaQA Slayer ma exact_match 0,005 i 0,015 (LFM2.5: 0,080 i 0,310). Odpowiada pełnym zdaniem, a część trafień w ocenie „zawiera odpowiedź" to echo pytania. Po jego odjęciu zapas wynosi ok. +5 pkt na TriviaQA (szacunek).

4. Stała odpowiedź w klasyfikacji. Kalibracja priorytetu etykiety pokazuje, że BoolQ, CB, WiC, PSC, CBD i CoLA nie niosą sygnału ani u Slayera, ani u LFM2.5. Wyjątkiem jest sentyment: SST-2 po kalibracji rośnie z 0,505 do 0,585 u Slayera (słaby sygnał, $z \approx 2{,}3$) i do 0,855 u LFM2.5.

5. Gramatyka. BLiMP: 62 z 67 paradygmatów powyżej 0,5. Cztery z pozostałych pięciu są poniżej albo na poziomie losowym także u Pythii-1B, więc traktujemy je jako cechę skali. Piąty

(`matrix_question_npi_licensor_present`: Slayer 0,497, Pythia 0,632) to luka Slayera, ale część błędów wynika tam z przyrządu: suma logprob nagradza krótsze zdanie. MultiBLiMP-PL: 0,99.

Co z tego wynika dla 1.07. Zadania z pierwszego wiersza tab. 1 są celami danych, bo rozwiązuje je model tej skali przy znacznie większym budżecie tokenów. LFM2.5-1.2B-Base trenowano na 28 bln tokenów (karta modelu na HF), czyli ok. 1 900 razy więcej niż 1.06. Różnica wobec LFM2.5 mierzy więc budżet i dane razem, a nie samą skalę modelu. Zadania z drugiego wiersza mają niski priorytet przy obecnym budżecie. Obecny panel nie wykazał tam umiejętności u żadnego modelu, ale nie dowodzi to, że danymi nie da się ich poprawić. Liczby na zadaniach z trafieniami przecieku w korpusie 1.06 (oznaczone na Space jako *flagged*) czytamy tylko na pozycjach bez trafień (sekcja 4).

2.1 Liczby 1.06: panel bench50 i track

Panel bench50 (200 pozycji na zadanie, protokół `bench50-v0.3.1-panel200`). Wybrane zadania, których dotyczą mankamenty z tej sekcji. Odniesienie: LFM2.5-1.2B-Base w tym samym protokole. Kolumna „bez trafień" to wynik Slayera na pozycjach panelu bez 13-gramu w korpusie 1.06 (skan korpusu 1.06).

zadanie	metryka	Slayer 1.06	bez trafień (n)	LFM2.5	poziom losowy
T02 ARC-C	acc_norm	0,250	0,250 (196)	0,490	0,25
T32 MMLU	acc	0,283	0,294 (194)	0,563	0,25
T45 MedMCQA	acc	0,245	0,241 (191)	0,405	0,25
T37 LLMzSzŁ	acc	0,300	0,298 (191)	0,290	0,25
T24 Belebele-PL	acc	0,300	—	0,300	0,25
T05 HellaSwag	acc_norm	0,365	0,365 (200)	0,625	0,25
T42 NQ-Open	exact_match	0,005	0,005 (195)	0,080	—
T43 TriviaQA	exact_match	0,015	0,016 (188)	0,310	—
T01 BLiMP	acc	0,841	0,838 (197)	0,801	0,50

Przy $n = 200$ i $p \approx 0{,}3$ błąd standardowy pojedynczego wyniku wynosi ok. 0,03. Przedziały CI95 opublikowane na stronie wyników są za wąskie: bootstrap warstwowy zaniżał wariancję o czynnik $(n_h - 1)/n_h$. Dotąd przeliczyliśmy trzy zadania (T01, T32 i T47; dwa pierwsze są w tabeli): ich poprawione przedziały są 1,09–1,32 raza szersze. Pozostałe zadania przeliczy dopiero poprawka strony. Werdykty i poprawka Holma się nie zmieniają, bo p pochodzi z testu permutacyjnego. Poprawka jeszcze nie weszła, dlatego tu podajemy tylko wartości, bez przedziałów.

Track (protokół v8), 1.06 = krok 13 848. ARC-Easy 52,99 %, BLiMP 76,12 %, WikiText-2 byte-PPL 2,2849, MultiBLiMP-pl 98,41 %, ARC-Easy-PL EU20 45,03 %. Są to liczby innego protokołu niż panel bench50 (np. BLiMP: tu pełne 67 000 par, tam panel 200 pozycji z innym kodem), więc obu tabel nie łączymy (sekcja 9).

3 Dane: skład ok. 9 mld tokenów i uzasadnienie

3.1 Punkt wyjścia: co widział 1.06

Slayer 1.06 skończył na kroku 13 848, czyli trening zużył $13\,848 \times 1\,048\,576 = 14\,520\,680\,448$ tokenów (13,52 tokenu na parametr przy $P = 1\,073\,912\,851$). Pliki ośmiu wsadów zawierają łącznie 14 524 133 431 tokenów treningowych: web PL 7,835 mld, rdzeń PL 2,707 mld, teksty prawne PL 1,339 mld, EN 2,643 mld. EN to więc 18,2 % tokenów v6. Karta zbioru na HF podaje 63/19/8/10 (EN 10 %), ale to *wagi docelowe* buildera wsadów (pole `wagi` w manifestach), a nie

zrealizowany udział w tokenach v6 (pole `tokeny_v6_na_komponent`). W tym tekście używamy udziałów zrealizowanych. Każdy dokument rdzenia, prawa i EN był widziany dokładnie raz (przedziały w manifestach sumują się do jednej epoki, bez dziur i nakładania), a pule rdzenia, prawa i EN są wyczerpane: świeżego tekstu tych rodzajów w naszym korpusie nie ma.

3.2 Skład 1.07

Cel tego etapu to ok. 9 mld nowych tokenów, jako pierwszy krok drogi do co najmniej 40 mld łącznie. Skład dobieraliśmy według trzech zasad:

1. **Polski zostaje stałym składnikiem** (replay). Udział EN w nowych danych rośnie do 44 % (z 18 % w 1.06), więc część rdzenia i prawa powtarzamy. Praca o dalszym treningu na innym języku (arXiv:2403.08763) bada pełną zmianę języka EN→DE, a u nas polski to nadal ok. 70 % całej diety. Powtórka jest tu więc ostrożnością, a nie wymogiem wynikającym z tej pracy.
2. **Wykluczamy dokładne powtórki EN.** Dokument EN, którego klucz tekstowy (`sha256` znormalizowanego tekstu, 16 znaków hex) jest w EN korpusu 1.06, wypada. To samo dotyczy duplikatów w obrębie budowy.
3. **Tekst przechodzi tę samą obróbkę co w 1.06:** maskowanie danych osobowych funkcją `maskuj()` z buildera 1.06 (import po sumie `09993148`), tokenizer v6 (`0640d3bd`), EOS po dokumencie.

składnik	mld tok. (zbudowane)	źródło i uwagi
PL web, rezerwa HPLT	3,120	pliki puli nietknięte przez 1.06; 2 448 525 dok., `a00c6921`; po wycięciu przecieku i maskowaniu PII: 3,110 (`2480ac94`)
PL rdzeń, powtórka	1,000	podzbiór widzianych w 1.06, losowy po haszu, minus lista wykluczeń `ca61b7ff`; po wycięciu przecieku 0,983
PL prawo, powtórka	1,004	0,704 (połowa `09993148`, całość) + 0,300 (połowa `f300328c`); po wycięciu przecieku 0,912 (długie akty prawne wypadają w całości przy jednym 13-gramie)
EN FineWeb-Edu (świeże z minimal-en-corpus-5b)	0,978	ODC-By; 840 133 dok.; 36 996 wykluczonych jako kopie EN 1.06
EN FineMath	0,237	ODC-By; 152 623 dok.
EN open-web-math	0,225	ODC-By; 86 621 dok.
EN DCLM-baseline (podzbiór)	0,245	CC-BY-4.0; 177 946 z 577 235 kandydatów, cięcie na całych dokumentach
EN FineWeb-Edu `sample/10BT` (4 pliki)	2,254	ODC-By; 2 035 410 dok., `daa45a29`; 288 312 kopii EN 1.06 i 250 222 kopii wierszy wyżej wykluczonych
razem	9,06	po wycięciu przecieku i maskowaniu: **8 891 005 707** tokenów w 9 plikach (sekcja 4)

Tabela 2: Skład 1.07: `tokens_out` z manifestów przebiegów (z EOS). EN z minimal-en-corpus-5b razem 1 686 034 957 (`bfae642f`), po pełnym czyszczeniu v2: 1 650 618 814 (`332589ee`); FineWeb-Edu 10BT po pełnym czyszczeniu v2: 2 235 660 025 (`a1e95968`).

Budżet FineWeb-Edu 10BT liczyliśmy z rzeczywistych liczb pozostałych plików, z zapasem 0,06 mld na dokumenty wycięte po skanie przecieku. Wycięcie okazało się większe (2,1 % EN, 9–10 % prawa), więc bieg ma ok. 8 479 zamiast 8 583 kroków. Nie dobieramy danych: launcher liczy kroki z bajtów, a każde okno jest użyte raz.

3.3 Dlaczego taki skład

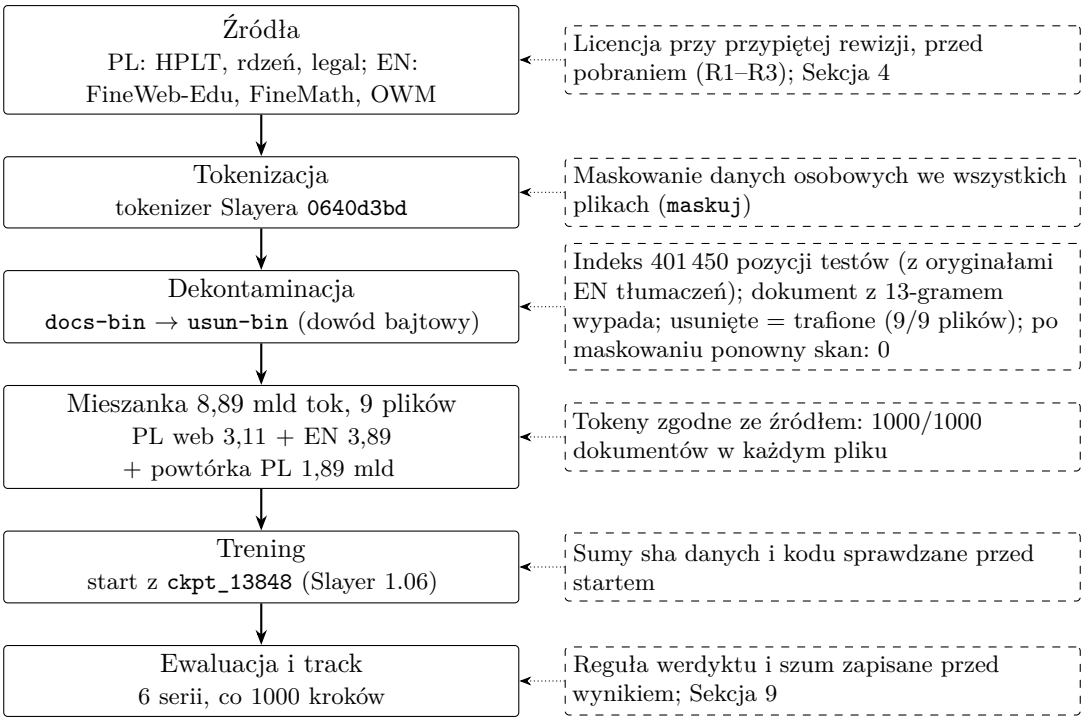
Powtórka PL zamiast samego EN. Większy udział EN jest dopuszczalny, bo polskiego tekstu jest po prostu mniej. Wariant bez powtórki obniżyłby udział rdzenia w całej diecie (23,5 mld po 1.07) z 18,6 % do 11,5 %, a prawa z 9,2 % do 5,7 %. To jest zmiana rozkładu w stronę EN, choć znacznie mniejsza niż pełna zmiana języka badana w arXiv:2403.08763. Powtórka kosztuje drugą epokę na części danych: po czyszczeniu wraca 0,983 mld rdzenia (36 % jego tokenów z 1.06) i 0,912 mld prawa (68 %), a reszta korpusu jest widziana raz.

FineWeb-Edu jako trzon EN. Ma najprostszą licencję (ODC-By), największą skalę i jest wybrany pod treści edukacyjne. FineMath i open-web-math dokładają matematykę, a DCLM w podzbiorze dokłada różnorodność webu. DCLM bierzemy tylko w budżecie 0,245 mld z dostępnych ok. 0,68 mld, żeby nie przesuwać EN ponad potrzebę.

Czego nie bierzemy. Źródeł o nieznanej licencji (cc-news, starcoderdata, wildchat, ultrachat, tiny-textbooks, scientific-papers, open-subtitles) oraz tekstów syntetycznych z modeli o restrykcyjnych warunkach (reguła R1). ARC-MIX odpada, bo zawiera wzmocnione pozycje związane z ARC, więc skaziłby oś ARC-Easy. Danych F/K z partii 1 nie włączono do przygotowanej puli dziewięciu plików. Wynik zakończonej sondy (sekcja 7) nie uruchamia automatycznej zmiany zbioru; decyzja o dodatkach należy do zespołu treningowego.

3.4 Wycięcie przecieku

Każdy plik przechodzi `docs-bin`, a dokumenty z trafieniem 13-gramu wypadają w `usun-bin` przed treningiem (sekcja 4). Skan bazy partii 1 pokazał, że nie jest to formalność: w 105 mln tokenów bazy partii 1 (mieszanka webu, rdzenia, prawa i EN) było 165 dokumentów z fragmentami pasaży testów czytania ze zrozumieniem (głównie PolQA).



Rysunek 1: Droga danych Slayera 1.07. Etapy po lewej, bramki po prawej (linia przerywana): dane przechodzą dalej tylko po spełnieniu bramki. Po wszystkich bramkach zostaje 8,89 mld tokenów w 9 plikach; skład w Sekcji 3, wyniki dekontaminacji w Sekcji 4.

4 Dane: licencje i dekontaminacja

Każde źródło danych przechodzi dwie kontrole, zanim trafi do treningu: kontrolę licencji przed pobraniem i skan przecieku pozycji testowych na gotowym pliku treningowym. Obie dają zapis z sumami kontrolnymi, który trafia do karty modelu.

4.1 Licencje

Źródło dopuszczamy tylko wtedy, gdy licencja zbioru przy przypiętej rewizji pozwala na trening i publikację wag. Trzy reguły odrzucają źródła niezależnie od licencji samego zbioru:

- **R1:** bez tekstów wygenerowanych przez modele, których warunki zakazują trenowania innych modeli na ich wyjściach (GPT, Gemini, Llama 3.1);
- **R2:** tylko pliki danych (parquet), bez skryptów ładujących i bez wykonywania kodu z repozytorium zbioru;
- **R3:** bez treści OpenStax, także w kopiach i adaptacjach na innych platformach, bo warunki wydawcy zakazują użycia do trenowania modeli językowych.

Reguła R3 okazała się istotna w praktyce. W zbiorze LibreTexts filtr wsadów (słowo „openstax” w identyfikatorze, autorze, tytule, adresie książki lub treści) wskazał 1 476 dokumentów w dziedzinach neutralnych (matematyka, statystyka) i 5 772 z ok. 13 tys. (ok. 44 %) w dziedzinach docelowych (fizyka, chemia, biologia, medycyna). Wszystkie zostały wycięte przed budową wsadów.

4.2 Indeks pozycji chronionych

Skan porównuje dane treningowe z indeksem wszystkich pozycji testowych, którymi model będzie mierzony: 263 255 pozycji z 50 zadań naszej tablicy (bench50) oraz 132 543 pozycji ze zbiorów,

źródło	licencja	werdykt
FineWeb-Edu	ODC-By 1.0	tak
FineMath	ODC-By	tak
open-web-math	ODC-By (publikacja)	tak, z zapisem źródła licencji
DCLM-baseline 1.0	CC BY 4.0	tak („research only” dotyczy modeli DCLM)
HPLT 3.0 (PL)	CC0 kompilacji, TDM art. 4 DSM	tak
LibreTexts (bez OpenStax)	CC BY / CC BY-SA / PD / GFDL per dokument	tak
Nemotron-CC v2	licencja NVIDIA (gated)	nie, bez lektury warunków
syntetyki GPT/Gemini/Llama	warunki generatora	nie (R1)
OpenStax i pochodne	zakaz trenowania LLM	nie (R3)

Tabela 3: Werdykty licencyjne dla źródeł 1.07.

na których mierzy zewnętrzny zespół replikujący (pełny BLiMP, MultiBLiMP-PL, WikiText-2, Belebele-PL, MMLU, Global-MMLU-PL, LLMzSzŁ, PIQA, SIQA, HellaSwag), każdy przy przypiętej rewizji. Razem 395 798 pozycji. Po zewnętrznej recenzji indeks uzupełniono o zbiory, które mierzy tablica treningu, a których w nim brakowało, oraz o angielskie oryginały zbiorów tłumaczonych: ARC-Easy (2 376), ARC-Easy-PL (2 376) i angielskie teksty Belebele z FLORES (900), razem 5 652 pozycje. Wszystkie pliki 1.07 przeszły skan także na tym indeksie. Zbioru EWoK nie ma w indeksie (archiwum chronione hasłem, licencja ogranicza obieg), więc wyniki na nim raportujemy jako niezeskanowane.

4.3 Metoda

Tekst jest sprowadzany do małych liter i dzielony na słowa (`\w+`). Pozycja, której choć jedno pole treści ma co najmniej 13 słów, jest reprezentowana przez wszystkie 13-gramy słowne swoich pól. Gdy żadne pole nie osiąga 13 słów, pozycję reprezentują całe pola o długości co najmniej $\max(3,\ 0{,}6 \cdot L)$ słów, gdzie L to długość najdłuższego pola (dopasowanie dokładne). Pola kategoryczne (etykiety, nazwy przedmiotów) są pomijane. Dokument treningowy, który zawiera choć jeden 13-gram pozycji, jest **usuwany** przed treningiem. Dopasowania krótkie (krótka odpowiedź lub opcja obecna w tekście) liczymy i raportujemy, ale nie usuwamy na ich podstawie dokumentów, bo nie są przeciekiem pozycji. Każde trafienie haszu jest weryfikowane słowo w słowo z tekstem pozycji. Każdy skan, także skan plików tokenizowanych, ma kontrolę dodatnią (podłożone pozycje, w plikach tokenizowanych zakodowane tym samym tokenizerem i przepuszczone tą samą ścieżką, muszą zostać znalezione w komplecie) i ujemną (losowy tekst nie może dać trafienia); niepowodzenie którejkolwiek zatrzymuje skan. Dla plików tokenizowanych skan dekoduje plik tokenizerem przypiętym sumą kontrolną i działa równolegle na wszystkich rdzeniach. Przed skanem sprawdza, że plik powstał tym tokenizerem: dla 100 dokumentów rozłożonych po pliku ponowne zakodowanie zdekodowanego tekstu musi odtworzyć te same tokeny w co najmniej 95 % przypadków (plik z obcym słownikiem dałby fałszywie czysty wynik; na danych PL wychodzi 100/100, po permutacji słownika 0/100). Usunięcie dokumentów odbywa się na tym samym pliku, którego suma, układ i liczba dokumentów są sprawdzane względem raportu skanu. Wynik usunięcia jest porównywany z wejściem dokument po dokumencie, bajt w bajt: każdy zachowany dokument musi być identyczny z odpowiadającym mu dokumentem wejścia. Wynik skanu każdego zachowanego dokumentu jest więc taki sam jak w pierwszym przebiegu, a drugi pełny skan nie jest potrzebny.

4.4 Co skan znalazł przed pierwszym biegiem

W pierwszej wersji wsadu formatu (zadania matematyczne AQuA) 819 z 2 985 pozycji testu MathQA (27 %) miało 13-gramy treści lub rozwiązania w danych. MathQA powstało z AQuA, a wcześniejszy filtr porównywał tylko pytania. Usunięcie 2 646 wierszy z trzech wsadów dało 0 trafień 13-gram w ponownym skanie (dopasowania krótkie na opcjach odpowiedzi zostały i są raportowane jako liczba). W bazie wspólnej (mieszanka tej samej rodziny co dane 1.06) 165 dokumentów (0,6 % tokenów) zawierało fragmenty Wikipedii, na których zbudowane są DROP, PolQA, PoQuAD, SQuAD2 i BoolQ. Druga próbka tej samej puli (ramię kontrolne, 77,5 % wspólnych dokumentów) miała 162 takie dokumenty w 14 z tych samych zadań. Zadania docelowe pierwszego eksperymentu miały w obu próbkach 0 trafień 13-gram; 15 zadań z trafieniem wyłączono z interpretacji tego eksperymentu. W treningu 1.07 takie dokumenty są usuwane bez wyjątków.

4.5 Wynik dla danych 1.07

plik	dokumenty usunięte	tokeny usunięte	tokeny po
EN: FineWeb-Edu, FineMath, open-web-math, DCLM	8 065	35,4 mln (2,10 %)	1 650,6 mln
EN: FineWeb-Edu `sample/10BT`	6 065	18,5 mln (0,82 %)	2 235,7 mln
PL: web (rezerwa HPLT)	2 924	9,6 mln (0,31 %)	3 110,4 mln
PL: powtórka rdzenia i prawa (6 plików)	17 454	109,6 mln (5,47 %)	1 894,3 mln
razem	34 508	173,1 mln (1,91 %)	8 891,0 mln

Tabela 4: Dokumenty z 13-gramem pozycji testowej usunięte z plików 1.07 przed treningiem.

W danych angielskich najwięcej trafień dotyczyło zadań matematycznych (MathQA), MMLU i angielskojęzycznych części egzaminów LLMzSzŁ; w polskim webie głównie zadań czytania opartych na Wikipedii. W powtórce najwięcej ubyło tekstów prawnych (9–10 % tokenów): część pytań testowych cytuje przepisy, a jeden wspólny 13-gram usuwa cały, zwykle długi akt. Trafienia w ARC-Challenge były nieliczne (12 i 3 dokumenty). Indeks uzupełniający znalazł w danych angielskich jeszcze 103 dokumenty: 82 z tekstami FLORES (źródło Belebele) i 21 z pytaniami ARC-Easy; w danych polskich nie znalazł nic. Wszystkie trafione dokumenty usunięto bez wyjątków.

4.6 Ograniczenia

Skan wykrywa przecieki dosłowne i bliskie dosłownym. Nie wykrywa parafraz ani zadań z tej samej rodziny szablonów (przykład: AQuA i MathQA po usunięciu wspólnych 13-gramów), dlatego wyniki na takich zadaniach opisujemy z etykietą „źródło wspólne z danymi”. Dotyczy to także zadań PolQA i PoQuAD: korpusy pasaży, z których powstały, są częścią polskiego rdzenia używanego od 1.06 (także w powtórce 1.07). Skan usuwa dokumenty zawierające 13-gram pozycji, ale nie cały korpus źródłowy, dlatego wyniki tych dwóch zadań w 1.07 są tylko opisowe i nie wchodzą do oceny względem 1.06.

Dane osobowe (adresy e-mail, numery PESEL, NIP, REGON, dowodu i telefonu) są maskowane w każdym pliku 1.07 tym samym narzędziem. Polski web pochodzi z puli, którą oczyszczono z danych osobowych już przy przygotowaniu (w 2,7 mln dokumentów źródłowych został jeden adres e-mail, nieobecny w wybranej części); maskowanie zmieniło w nim jeszcze 4 426 dokumentów (0,18 %), głównie numery telefonów. Dokumenty zmienione przez maskowanie są ponownie

skanowane.

5 Sposób treningu

Poniższa konfiguracja jest wariantem do przeglądu i zatwierdzenia przez zespół treningowy, nie przydziałem maszyny ani zgodą na uruchomienie biegu.

5.1 Start i geometria kroku

1.07 jest dalszym treningiem 1.06: startuje z checkpointu 13 848 (`1fc7396c`) razem ze stanem optymalizatora (`--resume`). Trener to r24.2 (`46f83b51`): r24.1 (`881cb055`, którym trenowano 1.04) z dodaną opcjonalną diagnostyką `--global-batch-sha`. Bez tej flagi wartości, kolejność danych i matematyka są te same. 1.04–1.06 trenowano na 4 i 8 kartach L40S; roboczy wariant 1.07 zakłada 8 kart RTX 4090 (albo 5090). Geometria kroku jest ta sama: $2 \times 16 \times 8 \times 4096 = 1\,048\,576$ tokenów (mikro-batch × akumulacja × karty × kontekst). Przy 8 891 005 707 tokenach po czyszczeniu v2 daje to ok. 8 479 kroków, czyli koniec ok. kroku 22 327; dokładną liczbę launcher liczy z bajtów połączonego pliku.

5.2 Learning rate

LR jest stały: 6e-4 (AdamW) i 0,02 (Muon), bez wygaszania (`--decay-frac 0`), tak jak od 1.04. Stały LR zostawia otwartą drogę do kolejnych etapów (cel 40 mld) bez ponownego rozgrzewania. W eksperymencie 150 kroków od 13 848 zmiana lossu wobec 1.06 wyniosła −0,0503911 nat dla wygaszania (A) i −0,0034372 nat dla stałego LR (B). Kontrast A−B to −0,0469539 nat (SE 0,0006), nie zmiana A względem 1.06 (repozytorium benchmarks-fabryka-ai, `research/slayer-1b/wygaszanie`). Według arXiv:2405.18392 zysk rośnie do ok. 20 % kroków, a uśrednianie wag mu nie dorównuje. Dlatego na koniec etapu planujemy **gałąź wydania z wygaszeniem** (ok. 850 kroków od ostatniego checkpointu stałego LR, 13–20 $), porównaną z avg10. Główny bieg zostaje na stałym LR, żeby kolejny etap startował bez rozgrzewania.

5.3 Kolejność danych

Trener czyta jeden plik `train.bin`. Pliki składników (tabela 2) łączymy więc w jeden plik, a sampler epokowy losuje permutację okien po całym pliku. Źródła mieszają się więc proporcjonalnie do liczby tokenów, a każde okno jest użyte co najwyżej raz. Licznik strumienia zaczyna się od zera (`--data-offset-steps=-13848`), więc 1.07 nie pomija żadnej części nowego pliku.

Ułożenie danych rosnąco po jakości przy stałym LR (arXiv:2511.18903, sekcja 6) nie wchodzi do 1.07. W naszym trenerze kolejność okien wyznacza permutacja, a nie układ pliku, więc taka zmiana wymaga nowego samplera, czyli nowego kodu przed bramką. Do tego ocenę jakości (`score`) ma tylko część FineWeb-Edu. To kandydat na tanią sondę przed kolejnym etapem.

5.4 Faza końcowa

Przygotowany zbiór 1.07 nie zawiera danych F/K z partii 1. Odczyt zakończonej sondy oddziela wynik BPB od hipotezy swoistości dziedzinowej (sekcja 7). Ewentualne dołączenie danych wymaga osobnej decyzji zespołu; samo fazowanie treningu nie zastępuje kwalifikacji danych.

5.5 Checkpointy i avg10

Trener zapisuje stan co 250 kroków na wypadek awarii, a launcher zatrzymuje z tego kopie (hardlink z sumą `sha256`) w siatce:

- co 1000 kroków (14 000 … 22 000),

- kamienie 13 998 (kontrola, niżej), 15 730, 18 590, 21 450 (przedłużenie siatki 1.04),
- ostatnie 10 checkpointów co 50 kroków, łącznie z ostatnim.

Z ostatnich dziesięciu powstaje model uśredniony (avg10). Do wydania wybieramy checkpoint według heldout PL (sekcja 9). Bazą porównania dla avg10 1.07 jest avg10 1.06, a nie pojedynczy checkpoint 13 848, bo samo uśrednienie wag 1.06 daje ok. −0,045 nat na heldoucie.

5.6 Kontrola: te same kroki na danych 1.06

Między 1.06 a 1.07 zmienia się naraz kilka rzeczy (udział EN, nowy web PL, druga epoka rdzenia i prawa, liczba kroków). Żeby oddzielić efekt danych od efektu samego dalszego treningu, mamy ramię kontrolne, które już istnieje: ramię B eksperymentu wygaszania. To 150 kroków od 13 848 na stałym LR 6e-4 na mieszance tej samej rodziny co 1.06 (zbiór `slayer-pl-8x3b` w rewizji `d50df04a`). Dlatego 1.07 zapisuje checkpoint dokładnie w kroku 13 998, a wpływ danych na początku biegu czytamy jako $\Delta = 1.07@13\,998 - B@13\,998$, na tych samych osiach. Dla dłuższych odcinków hipotezą zerową „dłuższy trening" jest trend 1.04→1.06 zapisany przed startem (sekcja 9).

5.7 Kontrole przed startem

Launcher zatrzymuje się, jeśli suma `sha256` trenera, tokenizera, checkpointu 13 848 albo któregokolwiek pliku danych nie zgadza się z wpisaną. Po starcie sprawdza w logu `RESUME @ 13848`, liczbę parametrów i liczbę kart. Przed treningiem: 10 minut pomiaru tempa na 8 kartach i test łącza NCCL (na maszynach vast z 8 kartami RTX 4090 potrzebne jest `NCCL_P2P_DISABLE=1`).

6 Metody uczenia: co jest dowiedzione, a co jest hipotezą

Metodę przyjmujemy, gdy ma dowód w literaturze przy skali bliskiej naszej albo w naszym pomiarze. Liczby poniżej to wyniki autorów prac, a nie nasze pomiary. Przeniesienie każdej z nich na Slayera (1B, PL+EN, dalszy trening z 13 848) jest hipotezą do sprawdzenia według sekcji 9.

6.1 Ułożenie danych w czasie

Kolejność rosnąco po jakości przy stałym LR (kandydat, nie w 1.07). Luo i in. (arXiv:2511.18903, ICLR 2026) trenują modele 1,5B na 30 mld tokenów. Ułożenie danych rosnąco po jakości *wyraźnie* wygrywa u nich z losowym tasowaniem przy stałym LR, ale przewaga znika przy standardowym wygaszaniu LR. Umiarkowane wygaszanie razem z uśrednianiem ostatnich checkpointów daje +1,64 % średnio na zestawie benchmarków. Slayer trenuje na stałym LR $6 \cdot 10^{-4}$ bez wygaszania, a uśrednianie ostatnich checkpointów (avg10) mamy w planie. Wygaszanie mamy już zmierzone: po 150 krokach zmiana lossu wobec 1.06 wyniosła −0,0504 nat dla wygaszania i −0,0034 nat dla stałego LR. Kontrast wygaszanie minus stały LR wyniósł −0,0470 nat (SE 0,0006; sekcja 5). Hägele i in. (arXiv:2405.18392) pokazują, że stały LR z krótkim wygaszeniem skaluje się jak harmonogram kosinusowy, a uśrednianie wag poprawia wynik wzdłuż biegu bez dodatkowego kosztu. Etykieta jakości dla EN jest w danych (FineWeb-Edu: kolumny `score` i `int_score`), ale tylko w części FineWeb-Edu. **W 1.07 tej metody nie stosujemy:** sampler trenera losuje permutację okien po całym pliku, więc kolejność dokumentów w pliku nie przenosi się na kolejność treningu. Wymagałoby to samplera sekwencyjnego, czyli nowego kodu trenera (sekcja 5). **Status: hipoteza oparta na jednej pracy o bliskiej skali,** kandydat na osobną próbę przy stałym LR.

Faza końcowa z danymi dziedzinowymi (kandydat). Blakeney i in. (arXiv:2406.03476) podbijają dane dziedzinowe w ostatnich 10–20 % treningu modelu 7B (1 bln tokenów) i uzyskują do +6,90 pp na MMLU, +8,26 pp na GSM8K i +6,17 pp na HumanEval wobec bazowej mieszanki. U nas to miejsce na dane formatu i wiedzy z sondy 1.07b, jeśli sonda pokaże ruch ponad szum (sekcja 7). **Status: hipoteza; skala pracy jest ok. 7 razy większa w parametrach.**

Curriculum językowy od łatwego do trudnego (odrzucony). Campos nie znalazł przekonujących dowodów, że curriculum poprawia trening modelu językowego (ocena na GLUE; arXiv:2108.02170). Podsumowanie BabyLM 2023 ocenia próby curriculum jako „largely unsuccessful" (Warstadt i in., CoNLL 2023, ACL Anthology). Nie stosujemy.

6.2 Zmiana rozkładu: więcej EN po treningu głównie po polsku

Ibrahim i in. (arXiv:2403.08763) badają dalszy trening przy zmianie języka (EN→DE, 405M). Według abstraktu, żeby dorównać treningowi od zera na wszystkich danych, *wystarcza* połączenie trzech rzeczy: powtórki części starych danych, ponownego podniesienia LR i jego ponownego wygaszenia. Gupta i in. (arXiv:2308.04014, Pythia 410M) pokazują, że ponowne podniesienie LR najpierw zwiększa loss na starych i nowych danych, a na dłuższą metę poprawia wynik na nowych.

Wniosek dla 1.07 jest słabszy niż w tych pracach. Badają one pełną zmianę języka, a u nas polski to nadal ok. 70 % diety po 1.07. **Stały udział PL (powtórka rdzenia, legal i web PL) traktujemy więc jako ostrożność, a nie wymóg wynikający z tych prac.** Osie PL liczą się jako koszt w regule werdyktu (sekcja 9). Ponowne podniesienie LR nas nie dotyczy, bo trenujemy na stałym LR. Dotyczyłoby to dopiero zmiany harmonogramu.

6.3 Tekst dydaktyczny i rozwiązane ćwiczenia

Gunasekar i in., arXiv:2306.11644v1, badają model Phi-1 o 1,3 mld parametrów na zadaniu generowania kodu Python. Ich zbiór pretreningowy ma mniej niż 7 mld tokenów: około 6 mld filtrowanego kodu oraz mniej niż 1 mld syntetycznych podręczników. Model widział jednak **ponad 50 mld tokenów**, ponieważ dane powtarzano. Wielkość zbioru nie jest liczbą ekspozycji modelu. Po pretreningu następuje dostrajanie na około 180 mln tokenów ćwiczeń. Autorzy raportują około 29 % HumanEval dla Phi-1-base i 50,6 % dla modelu po etapie CodeExercises. Nie przypisujemy tej różnicy samym podręcznikom: zmienia się również etap uczenia i dodane ćwiczenia.

Przenośna jest zasada selekcji: samodzielny opis, przykład, poprawne rozwiązanie i zróżnicowane ćwiczenia zamiast nieczytelnych fragmentów lub powtarzanego boilerplate. Nie jest przenośny automatycznie wynik liczbowy: praca dotyczy kodu, a nie ogólnego modelu PL+EN. Podręczniki i ćwiczenia generował GPT-3.5, więc **nie importujemy ich danych przy regule R1**. Adaptacja na dozwolonych tekstach i programowo sprawdzalnych zadaniach pozostaje hipotezą do zbadania.

Wsparciem dla selekcji jakości jest SmolLM2, arXiv:2502.02737v1. Autorzy porównują źródła webowe przy równym modelu i budżecie 350 mld tokenów; FineWeb-Edu i DCLM dają różne mocne strony. To uzasadnia dobór mieszanki pod umiejętności, a nie kopiowanie jednego stosunku źródeł jako uniwersalnego. Pełny model 1,7B trenowano na około 11 bln ekspozycji. Jego etapy zmieniają jednocześnie dane, LR i liczbę tokenów, więc ich porównanie nie izoluje przyczynowego efektu samej kolejności.

6.4 Przeplatanie tekstu z zadaniami w pretreningu

Cheng i in., arXiv:2406.14491v2, proponują *instruction pre-training*: do części tekstów dodają zadania oparte na ich treści. Cel uczenia pozostaje taki sam jak w zwykłym pretreningu: przewidywanie następnego tokenu i strata na wszystkich tokenach. Nie jest to RLHF ani samo dostrajanie po zakończeniu pretreningu. W porównaniu modeli 1,3B uczonych na 100 mld tokenów przy równym budżecie wynik zależy od osi:

Metryka	Zwykły pretrening	Instruction pre-training
ARC-C	28,8	30,9
MMLU	25,7	27,3
HellaSwag	54,9	54,3

Nie jest to dowód poprawy każdej umiejętności. W pracy pary tworzył dostrajany syntezator Mistral-7B; warunki generatora, pochodzenie jego danych i przecieki wymagają osobnej kontroli przed użyciem takiego korpusu. Bliska liczba parametrów nie usuwa różnicy między pretreningiem od zera na 100 mld a krótkim dalszym treningiem Slayera.

6.5 Hipoteza do partii drugiej, bez zmiany biegu 1.07

Hipoteza: przy tej samej puli faktów i budżecie przeplatanie opisu z programowo sprawdzalnymi pytaniami poprawia wykorzystanie informacji bardziej niż sam tekst, bez nieakceptowalnego kosztu dla polskiego. Proponujemy świeże C, C2 i I z tego samego checkpointu 1.06 `ckpt_13848`, przypiętego w paczce kodu partii pierwszej. C/C2 dostają teksty z tej samej puli co I, ale I zastępuje proponowane 20 % slotów domenowych tekstem przeplatanym zadaniami. Odpowiedzi wynikają z tekstu lub reguły obliczeniowej; brak zewnętrznego LLM i źródeł testowych. Udział 20 % jest parametrem propozycji, nie optimum wykazanym w pracy.

Tokeny całego ramienia, pozostała baza, replay PL, pakowanie, LR, optimizer i wybór checkpointu pozostają takie same. Trzeba sprawdzić i zaraportować liczbę ekspozycji faktów: dodatkowe powtórzenie faktu w Q/A nie może być niezauważonym drugim czynnikiem. W tej próbie wybieramy wariant (a): C2 zawiera dokładnie te same dokumenty i tyle samo ekspozycji co C, ale w innej permutacji; sprawdzamy równość multizbioru dokumentów. Zatem C2 − C mierzy szum kolejności, nie doboru próbki. Nie kopiujemy sposobu budowy C2 z partii pierwszej, gdzie powstała inna próbka puli. Nie używamy też jej gotowych kontroli, bo ta próba ma inną mieszankę.

Budżet propozycji to 100 kroków na ramię przy 1 048 576 tokenach na krok, czyli 314 572 800 przetworzonych tokenów łącznie. Cenę i tempo trzeba zmierzyć przed biegiem. Przed i po mierzymy te same odłożone zadania, także w zmienionym układzie, cloze/BPB odpowiedzi i obowiązkowy heldout PL. Przed wynikiem zapisujemy główną oś, minimalny użyteczny efekt, próg względem szumu C2 − C i dopuszczalny koszt PL. Próba może pozostać nierozstrzygnięta z powodu małej dawki; brak zysku nie obala wyniku pracy na 100 mld tokenów. To projekt kontrolowanego eksperymentu, **nie wykonany pomiar** i nie warunek wstrzymujący przygotowanie 9 mld dla treningu 1.07.

7 Sonda 1.07b (partia 1): czy format i wiedza ruszają wynik

Pytanie. Czy niewielka domieszka danych formatu (F) albo tekstu dziedzinowego (K) rusza cele z sekcji 2 ponad szum treningu, zanim wydamy budżet na pełne 1.07?

Projekt. Cztery ramiona startują z 1.06@13848: jedna epoka, 100 kroków po 1 048 576 tokenów (104 857 600 tokenów treningu na ramię), liniowe wygaszanie LR do zera:

- **C**: baza (mieszanka scenariusza B z pomiarów zespołu benchmarków);
- **C2**: inna próbka dokumentów z tej samej puli, w innej kolejności (inny klucz sortowania przed przycięciem). Różnica C2 − C obejmuje więc szum kolejności i szum próbki danych;
- **F**: C z podmienionymi slotami na dane formatu: aqua_rat (48 882 pozycji) i syntetyczne pytania z luką PL/EN bez LLM (100 056 pozycji), szablony spoza ewaluacji;
- **K**: C z tymi samymi slotami podmienionymi na podręczniki dziedzinowe (LibreTexts EN, chemia AGH PL; 9 229 pozycji), bez pytań.

Wstawka ma w F i K po 13 891 979 tokenów i zajmuje te same pozycje w pliku. Odbiór miksera: F wchodzi w 100 % w każdym źródle i języku, a K w 99,89 % (EN) i 99,77 % (PL).

Reguła odczytu (zapisana przed wynikami). Dla zadania i metryki $\Delta = \bar{m}^{\text{ramię}} - \bar{m}^{C}$ na wspólnych pozycjach, SE(Δ) ze sparowanego bootstrapu ($B = 10\,000$), $z_k = |\bar{m}^{C2} - \bar{m}^{C}|$. Ruch zachodzi, gdy $|\Delta| > 2\,\text{SE}$ i $|\Delta| > 2\,z_k$, a przy $|\Delta| < 3\,z_k$ nazywamy go kruchym. Sukces F wymaga ruchu trafności z liter w górę na pełnym zbiorze oraz warunku (a): dolnej granicy CI95 ponad maksimum poziomu losowego i większości, na panelu dla MMLU/MedMCQA, na pełnym zbiorze dla LLMzSzŁ. Alternatywą jest ruch trafności w górę na sondzie formatu. W obu przypadkach udział najczęstszej litery musi być $< 50\,\%$; sam spadek tego udziału nie wystarcza. Zarejestrowana reguła sukcesu metryki wiedzy to ruch BPB poprawnej odpowiedzi w dół. Osobno przewidywano swoistość K: ruch na części CEL MMLU bez takiego ruchu na części KONTROLA. Poprawę kontroli raportujemy jako transfer; nie unieważnia ona sukcesu metryki BPB. Warunek $|\Delta| > 2\,z_k$ jest tu konieczny, a nie ostrożnościowy. W kontroli ujemnej na danych zespołu benchmarków (150 kroków stałego LR na danych 1.06, bez nowych danych; sekcja 9) BPB poprawnej przesuwa się na wszystkich 8 zadaniach o $z = 12$–62 liczone samym SE par, a acc_norm nie przesuwa się na żadnym zadaniu cloze. Samo SE par mierzy szum próby pytań przy ustalonych wagach, a nie ruch wag między checkpointami. Heldout użyty w ewaluacji partii 1 (`val.bin`, ten sam co w eksperymencie wygaszania) nakłada się z danymi treningowymi ramion, więc jego BPB podajemy tylko opisowo.

Dekontaminacja i wyłączenia. Wsady F i K przeszły skan 13-gramów na indeksie 395 798 pozycji testów z wynikiem 0 trafień (MathQA: 819 pozycji przed wycięciem). Baza C ma trafienia w 165 dokumentach na 15 zadaniach, głównie z pasażami Wikipedii (DROP, PolQA, PoQuAD, SQuAD2, BoolQ). Z nich 18 dokumentów leży w slotach podmienionych w F i K, a C2 jest inną próbką puli. Przeciek jest więc niesymetryczny między wszystkimi ramionami, dlatego te 15 zadań nie wchodzi do wniosków. Cele (ARC-C, Belebele-PL, MMLU, LLMzSzŁ, MedMCQA) mają 0 trafień. MathQA jest wyłączone dodatkowo, bo AQuA i MathQA mają wspólne źródło.

Wynik główny. Odczytano zakończone C/C2/F/K i punkt odniesienia 13 848 z końcowej paczki wyników, bez szuflady. Zachowano progi zapisane przed treningiem. Odbiór kompletności objął 69 plików. Niezależna implementacja potwierdziła na 10 kontrastach mianowniki, Δ, z_k, kierunek ruchu i kruchość; drobne różnice SE z losowania bootstrapu nie zmieniły żadnej klasyfikacji.

F nie ma ruchu trafności w górę na żadnym celu ani sondzie; na MedMCQA jest ruch w dół. Warunek udziału najczęstszej litery $< 50\,\%$ nie jest spełniony na żadnej z tych osi. W układzie przesuniętym trafność celów pozostaje w szumie. Koszt na kontroli Belebele cloze: −2,00 pkt ($2\,\text{SE} = 1{,}56$, $2z_k = 0{,}22$); Belebele z liter pozostaje w szumie.

Tabela 5: Format F wobec C: trafność z liter i konieczny warunek braku dominacji litery.

zadanie	n	Δ (pkt)	2 SE	$2z_k$	najczęstsza litera F
MMLU	14 042	−0,021	0,570	0,541	A 77,56 %
MedMCQA	4 183	−1,960	0,966	0,574	A 76,98 %
LLMzSzŁ	18 815	−0,096	0,371	0,117	B 92,90 %
sonda formatu	432	+0,231	4,668	0,926	A 51,39 %

Tabela 6: Wiedza K wobec C: BPB poprawnej odpowiedzi; niżej znaczy lepiej.

zadanie	n	Δ BPB	2 SE	$2z_k$	ruch
ARC-C cloze	1 172	−0,042139	0,009884	0,001949	poprawa
MedMCQA cloze	4 183	−0,038371	0,004562	0,032080	krucha poprawa
MMLU CEL	3 037	−0,034209	0,004375	0,001714	poprawa
MMLU KONTROLA	6 219	−0,003598	0,001366	0,001124	poprawa kontroli

Podział MMLU na 16 przedmiotów CELU, 24 KONTROLI i 17 neutralnych zapisano przed doborem korpusu. K poprawia BPB CELU silniej niż KONTROLI, ale obie grupy mają ruch w tym samym kierunku. Nie potwierdza to przewidywanej swoistości, ale spełnia regułę ruchu BPB; nie zamieniamy przewidywania w nowe kryterium sukcesu po wyniku. Trafność K na siedmiu pełnych zadaniach pozostaje w szumie. W ustalonej podgrupie CELU MMLU rośnie jednak o 1,087 pkt ($2\,\mathrm{SE} = 0{,}884$, $2z_k = 0{,}395$); wzrost o 0,418 pkt na KONTROLI pozostaje w szumie. To wynik pomocniczy wobec zarejestrowanej metryki BPB, a nie nowe kryterium.

Decyzja i zakres. F nie spełnia kryterium formatu. K ma sukces metryki BPB, lecz nie potwierdza hipotezy swoistości dziedzinowej. Przygotowana pula dziewięciu plików nie zmienia się automatycznie; decyzja o włączeniu dodatków należy do zespołu treningowego. To wynik dla tej dawki i tego projektu, nie dowód, że większa albo inna wstawka nie zadziała. Opisowa zmiana C wobec 1.06 wynosi −0,038174 BPB na ARC-C i −0,009919 na MMLU 5-shot; nie doliczamy jej do F − C ani K − C. Brakuje pełnej kontroli BLiMP w tej paczce, a heldout retencji nie jest niezależnym pomiarem generalizacji.

8 Audyt składu tematycznego danych

Po co. Dobór danych opisany w sekcji 3 opiera się na źródle, licencji i ocenie edukacyjnej (FineWeb-Edu), a nie na sprawdzeniu per dokument, że treść pokrywa się z brakami wiedzy mierzonymi w sekcji 2. Ten audyt jest przybliżoną, powtarzalną próbą takiej kontroli: pokazuje, jak próbka dokumentów rozkłada się na dziedziny i czy nowe pliki różnią się od powtórki 1.06.

Metoda. Z każdego pliku pobieramy 700 dokumentów równomiernie po jego długości (stały dobór, wynik deterministyczny), dekodujemy pierwsze ∼220 tokenów tokenizerem Slayera i liczymy embedding modelem `intfloat/multilingual-e5-base` (offline, bez sieci). Każdy dokument przypisujemy do najbliższej z siedmiu dziedzin wg podobieństwa kosinusowego do ręcznie napisanego opisu dziedziny. **To jest klasyfikacja zero-shot z opisami pisanymi ręcznie: dokładne wartości procentowe mają błąd rzędu kilku punktów, a kolejność plików jest wiarygodniejsza niż pojedyncza liczba.** Kod i wynik: `audyt/audyt_skladu.py`, `audyt/audyt-skladu.json`.

Odczyt. Nowe dane angielskie są wyraźniej skupione na dziedzinach celu niż powtórka 1.06: `en_mix` (mieszanka FineWeb-Edu, FineMath, open-web-math i DCLM) ma około 58 % treści na-

Tabela 7: Udział dziedzin celu (nauki przyrodnicze i medycyna + matematyka i informatyka) w próbce. Kolumna CEL to ich suma; dalej największy składnik spoza celu.

plik	grupa	CEL	nauki/med.	mat./inf.	największy spoza celu
`en_mix`	nowe	**57,9 %**	36,3 %	21,6 %	web 13 %, historia 12 %
`en_fineweb_edu`	nowe	41,7 %	31,9 %	9,9 %	web 20 %, historia 16 %
`pl_web`	nowe	37,6 %	27,4 %	10,1 %	web 43 %
`pl_replay` rdzeń	1.06	32,1 %	25,6 %	6,6 %	web 53 %
`pl_replay` prawo	1.06	25,9 %	14,3 %	11,6 %	prawo 41 %

uka/medycyna/matematyka, głównie przez 22 % matematyki i informatyki, wobec 32 % w rdzeniu i 26 % w prawie powtórki. To jest zmierzone wzbogacenie o wiedzę, której 1.06 miał mało.

Czego to nie mówi. Nawet najlepszy plik to w około 42 % treść spoza celu (web, historia, nauki społeczne), a `en_fineweb_edu` jest poniżej połowy na temat. `pl_web` to w większości ogólny polski web, nie wiedza dziedzinowa. **Wzbogacenie o wiedzę dotyczy niemal wyłącznie angielskiego**; celowanego polskiego materiału dziedzinowego ten zbiór praktycznie nie dokłada, a to właśnie polska wiedza podręcznikowa była jednym z zmierzonych braków 1.06 (sekcja 2). Przypisania ogólnego polskiego webu do „nauki/medycyny" (27 % w `pl_web`) są prawdopodobnie zawyżone przez klasyfikator, więc czytamy je ostrożnie. Audyt jest sygnałem o składzie, nie pomiarem skuteczności: czy to przesunięcie ruszy słabe punkty Slayera, rozstrzyga dopiero pomiar po treningu wobec ramienia kontrolnego (sekcja 9), a sonda partii 1 (sekcja 7) sygnalizowała, że sam ruch BPB nie był swoiście dziedzinowy.

9 Pomiar: kiedy 1.07 jest lepszy niż 1.06

9.1 Dwa poziomy pomiaru

1.07 mierzymy na dwóch poziomach, każdym innym kodem i w innym celu.

1. **Oś czasu treningu (track).** Ta sama tablica co dla 1.04–1.06, liczona na kolejnych checkpointach i publikowana na track.fabryka.ai. Służy do śledzenia biegu i do bezpiecznika osi EN.
2. **Pełne osie karty 1.07.** Pełne zbiory testowe z wynikiem dla każdej pozycji, liczone na checkpointach z kadencji. Z nich pochodzi werdykt „lepszy niż 1.06" (reguła werdyktu w tej sekcji).

Wyników z obu poziomów nie łączymy. BLiMP w protokole tracka (76,12 dla 1.06) i BLiMP w protokole zespołu benchmarków (79,21) to różne protokoły. Porównujemy wyłącznie 1.07 z 1.06 w tym samym protokole.

9.2 Protokół tracka (v8, dla 1.07 jako v9)

Kod: `evale_auto_v8.py`. Zmiana v8 → v9 dotyczy tylko miejsca, skąd brane są checkpointy, oraz nowego runu 1.07. Sposób liczenia się nie zmienia.

- **EN:** ARC-Easy (2 376 pytań, trafność), BLiMP (67 000 par, trafność), WikiText-2 jako byte-PPL = $\mathrm{PPL}_{\mathrm{tok}}^{n_{\mathrm{tok}}/n_{\mathrm{bajt}}}$ z niezaokrąglonego PPL tokenowego (PPL tokenowe zostaje jako diagnostyka).
- **PL:** MultiBLiMP-pl (3 272 pary) i ARC-Easy-PL EU20 (2 376 pytań).

- **Kalibracja przed pierwszym punktem:** Slayer1B-1.02 z HF (rewizja `bf7117b9`) musi dać dokładnie liczby z karty 1.02: ARC-Easy 48,99, BLiMP 74,71, byte-PPL 2,3735, MultiBLiMP-pl 3 219/3 272, ARC-Easy-PL 994/2 376. Inna liczba zatrzymuje publikację.
- **Czas:** ok. 989 s na punkt na jednej A100 (pomiar z 28.10). Czasu na 4090 nie mierzyliśmy.
- **Miejsce liczenia dla 1.07:** osobna karta 1×4090 w tym samym regionie co maszyna treningu. Checkpoint pobierany jest bezpośrednio z węzła treningu przez `rsync` tylko do odczytu. Służy do tego jednorazowy klucz z ograniczeniem do adresu i katalogu, który znika razem z maszynami. Przed liczeniem sha każdego checkpointu jest porównywana z `SHA256SUMS` trenera. Wynik trafia na track ze stacji. Pierwsza publikacja nazwy i etykiety runu przechodzi kontrolę treści (sekcja 4).

1.06 jako punkt startu. Run 1.06 na tracku (`f056bb5c`) ma oba checkpointy końca biegu i 22 punkty ze stałym LR w krokach 10 010–13 848. Różnica między dwoma ostatnimi checkpointami (z_k, definicja w regule werdyktu w tej sekcji) to tylko jedna para. Obok podajemy odchylenie standardowe reszt wokół trendu liniowego na tych 22 punktach (SD reszt, 20 stopni swobody):

seria	@13800	@13848	z_k	SD reszt
BLiMP (%)	75,82	76,12	0,30	0,45
ARC-Easy (%)	52,15	52,99	0,84	0,58
WikiText-2 byte-PPL	2,2882	2,2849	0,0033	0,0046
MultiBLiMP-pl (%)	98,50	98,41	0,09	0,15
ARC-Easy-PL EU20 (%)	45,20	45,03	0,17	0,40

Kolumny: wynik 1.06 w krokach 13 800 i 13 848 (trafność w %), z_k z tej pary oraz SD reszt z 22 punktów. Na czterech z pięciu osi para zaniża szum: na MultiBLiMP-pl i ARC-Easy-PL EU20 sąsiednie punkty z tych 22 różnią się o więcej niż $2z_k$ w 52 % par. Na ARC-Easy jest odwrotnie. Obie liczby pochodzą z jednego biegu, więc nie obejmują szumu seeda ani kolejności danych. SD reszt zawiera też rzeczywiste wahania treningu między checkpointami, a nie tylko szum pomiaru. Którą wielkość bierze reguła werdyktu, ustala reguła w tej sekcji.

9.3 Pełne osie karty 1.07: jak je liczymy

Osie i metryki ustala karta 1.07. Tu opisujemy tylko kod i dowody poprawności.

- **Scorer:** log-prawdopodobieństwo każdej opcji, liczone scorerem zespołu benchmarków (repozytorium benchmarks-fabryka-ai; `hipoteza_formatu.py`, wołany przez `ewal_ramion.py`, commit `4c2a6d6`, kod bez zmian). Zadania, których tam nie ma, dopisuje `diag107b.py`: litery A–D na MMLU (14 042), MedMCQA (4 183) i LLMzSzŁ, układ przesunięty, sondę formatu oraz MedMCQA w wersji cloze. Każdy plik zbioru jest przypięty sumą sha256 (`zbiory_pins.json`), a niezgodność zatrzymuje bieg.
- **Wynik:** jeden wiersz na pozycję (log-prawdopodobieństwo każdej opcji, bajty, złoto). Z niego liczymy trafność, BPB poprawnej odpowiedzi i udział każdej z liter A–D. Pary 1.07 − 1.06 tworzymy po identyfikatorze pozycji.
- **LLMzSzŁ:** 6 z 18 821 pozycji ma 5–6 odpowiedzi. W wariancie z literami A–D je pomijamy (n = 18 815), a lukę cloze − litery liczymy na wspólnych identyfikatorach.
- **Litery jednym przebiegiem modelu.** Scorer zespołu benchmarków liczy każdą literę osobnym przebiegiem tego samego kontekstu. Ponieważ litera to jeden token, wystarcza jeden przebieg na pozycję, a koszt zadań literowych spada ok. 4 razy. Warunek użycia: na próbce 200 pozycji z każdego zadania $\max|\Delta \log p| \leq 10^{-4}$ i 100 % zgodnych wyborów. Wyniki:

– tiny/CPU: $\max|\Delta| = 9{,}5 \cdot 10^{-7}$, 200/200 zgodnych wyborów w każdym z 7 zadań;

– Slayer 1.06 @13848 na GPU: $\max|\Delta| \leq 2{,}4 \cdot 10^{-5}$, 200/200 w 7/7 zadaniach;

– kontrola: wersja z celowo przesuniętą pozycją odczytu daje $\max|\Delta| = 0{,}151$ i 0/50 zgodnych wyborów, więc test odróżnia błędny kod od poprawnego.

W tokenizerze 0640d3bd każda litera po kontekście jest jednym tokenem we wszystkich pozycjach pełnych zbiorów, więc wariant ma zastosowanie wszędzie. Sposób liczenia każdego zadania zapisujemy w `wariant.json` obok wyników.

9.4 Kadencja

- Pełna tablica tracka co 1 000 kroków (ok. 1 mld tokenów), plus punkty obowiązkowe: start 13 848 (= 1.06), koniec każdej fazy danych oraz checkpoint końcowy.
- Ostatnie 10 checkpointów co 50 kroków (pod średnią avg10) liczymy samym loss na heldoucie, bez pełnej tablicy.
- Gęściej nie liczymy: nachylenie BLiMP w biegu 1.06 jest nieustalone ($p = 0{,}18$, a wahnięcie między krokami 8 600 i 10 010 to $-0{,}59$ pkt; repozytorium benchmarks-fabryka-ai), a rozrzut reszt BLiMP wokół trendu na tracku to 0,45 pkt. Punkty co mniej niż 200 kroków nie oddzielą więc trendu od szumu checkpointu.

9.5 Warunek wyniku: skan przecieku

Liczbę z zadania, którego pozycje testu mają 13-gram w danych treningowych, raportujemy wyłącznie z etykietą przecieku i obok wyniku na pozycjach bez trafień. Tak działa już strona wyników 1.06 (skan korpusu 1.06, receipt `bc6c168c`). Dla 1.07 każdy plik danych przechodzi przed treningiem skan i wycięcie dokumentów z trafieniem (sekcja 4), więc osie karty mają liczyć się na danych z zerem trafień 13-gram. EWoK nie jest w indeksie skanu, więc jego wynik zostaje bez tej gwarancji.

9.6 Reguła werdyktu (zapisana przed biegiem)

Pytanie, które 1.07 może rozstrzygnąć. Między 1.06 a 1.07 zmienia się naraz mieszanka, udział EN, druga epoka rdzenia i prawa, liczba kroków i sprzęt. Pełny bieg daje więc najwyżej werdykt „lepszy niż 1.06 po ok. 8,5 tys. kroków na nowej mieszance". Efekt *danych* oddzielamy tylko na odcinku 13 848→13 998, wobec ramienia kontrolnego B (sekcja 5): $\Delta_{\text{dane}} = 1.07@13\,998 - \text{B}$, liczone kodem i na zadaniach eksperymentu wygaszania, dla których wyniki B są zapisane per pytanie.

Kontrola ujemna reguły. Zanim przyjęliśmy metryki, sprawdziliśmy je na parze placebo B − 1.06: 150 kroków stałego LR na danych 1.06, bez nowych danych. Oś, która tu „rusza", nie odróżnia efektu danych od samego dalszego treningu. Tab. 8 podaje z liczone samym SE par.

Tabela 8: Kontrola ujemna: $z = |\Delta|/\text{SE}$ dla B − 1.06 (bez nowych danych).

	cloze				litery			
metryka	ARC-C	MedMCQA	SIQA	MultiBLiMP	ARC-C	MedMCQA	SIQA	PubMedQA
acc_norm	0,9	0,0	0,3	1,7	0,4	0,4	0,7	5,1
BPB poprawnej	15,7	25,3	11,9	32,1	24,8	22,0	61,9	14,3

BPB poprawnej odpowiedzi przesuwa się po 150 krokach na tych samych danych o 0,04 do 0,61 bita na bajt (wartość bezwzględna). Błąd standardowy par mierzy tylko szum próby pytań przy

ustalonych wagach, a nie ruch wag między checkpointami. Dlatego BPB poprawnej jest w 1.07 osią opisową, a werdykt stoi na acc_norm w formacie cloze, trafności par i BPB tekstu ciągłego. Trafność z liter też jest opisowa: na MedMCQA 1.06 wybiera „A" w 93 % pytań, więc zmiana ulubionej litery zmienia trafność bez zmiany wiedzy.

Różnica i szum. Dla zadania o pozycjach $i = 1, \ldots, n$ wspólnych dla obu modeli

$$\Delta = \frac{1}{n}\sum_{i=1}^{n}\left(m_i^{1.07} - m_i^{1.06}\right), \qquad \sigma = \sqrt{\mathrm{SE}(\Delta)^2 + z_k^2}, \qquad z = \Delta/\sigma.$$

SE(Δ) liczymy sparowanym bootstrapem po pozycjach ($B = 10\,000$, seed 20261028), klastrowanym po paradygmatach (BLiMP, MultiBLiMP-PL) i przedmiotach (MMLU). Szum checkpointu z_k to odchylenie standardowe reszt wokół prostej z 10 checkpointów 1.06 (13 400–13 848 co 50, te same, z których zbudowano avg10 1.06), liczone tym samym kodem przed pierwszym odczytem 1.07. Na osiach tracka bierzemy większą z tej wartości i SD reszt z 22 punktów tracka (protokół powyżej). Różnica dwóch sąsiednich checkpointów, której używaliśmy wcześniej, zaniża ten szum.

Tabela 9: Oś główna i rodzina osi werdyktu 1.07 (zamknięte przed biegiem).

oś	metryka
główna: heldout PL spoza danych 1.06 i 1.07	BPB ↓
ARC-Easy, ARC-C, MMLU, MedMCQA (EN)	cloze acc_norm ↑
BLiMP (EN)	trafność par ↑
WikiText-2 (EN)	BPB ↓
MultiBLiMP-PL (PL)	trafność par ↑
ARC-Easy-PL EU20 (PL)	cloze acc_norm ↑
opisowo: litery (MMLU, MedMCQA, Belebele-PL, LLMzSzŁ), BPB poprawnej, PolQA, PoQuAD	

Heldout. Zbudowano H107 z rezerwy HPLT po wykluczeniu identyfikatorów packów 0–7 i danych p08 (seed 1107). Podział wykonano po całych dokumentach, parzystych i nieparzystych w ustalonej kolejności, nie po kolejnych oknach:

część	dokumenty	tokeny z EOS	SHA256 pliku binarnego (prefiks)
wybór	1 056	1 042 856	`a1f904d5`
werdykt	1 056	1 058 519	`d3042fee`

Pliki, indeksy i listy id są zgodne z sumami manifestu H107; listy id obu części są rozłączne. Sama integralność plików nie dowodzi rozłączności treści z treningiem. Test wobec 9 plików 1.07 v2 dał 0/2 112 identycznych pełnych dokumentów i 0/2 112 wspólnych prefiksów 64-tokenowych. Osobny skan wykazał jednak co najmniej jeden wspólny 13-gram w 681 z 2 112 dokumentów H107 (32,24 %): 345 w części wyboru i 336 w części werdyktu. Nie jest to odsetek wspólnych tokenów. Przykłady obejmują wspólne szablony, ale nie wykazano, że wyjaśniają wszystkie trafienia. Brak pełnych kopii nie jest dowodem braku bliskich kopii. Kopii treści z packów 0–7 nie sprawdzono. Drugi heldout H' spoza HPLT (FineWeb2-HQ `pol_Latn`) jest zbudowany: 1 561 dokumentów, 1 050 043 tokeny z EOS, `H2.bin` `de8030e6` (manifest `ea431d93`). Wobec każdego z 9 plików v2 nie znaleziono identycznego pełnego dokumentu (0/1 561) ani prefiksu 64-tokenowego

(0/1 560; jeden dokument jest krótszy niż 64 tokeny bez EOS). Skan 13-gramów dał jednak trafienia w 256/1 561 dokumentów H' (16,40 %); nie jest to udział wspólnych tokenów ani dowód zapamiętania. Kontrola packów 1.06 pozostaje niewykonana. Wcześniejszy heldout z eksperymentu wygaszania jest opisowy. Jego część z rdzenia i prawa leży w powtórce 1.07 (33 % i 70 % dokumentów identycznych w całości), a część EN i web nie ma identycznych dokumentów w danych 1.07, ale widział ją 1.06. Mierzy więc retencję, a nie przyrost na nowym tekście. Pierwsza część H107 służy wyłącznie do wyboru checkpointu, druga wyłącznie do werdyktu (a). Wszystkie okna jednego dokumentu pozostają w tej samej części. Tak ograniczamy ponowne użycie danych wyboru; nie utożsamiamy rozłączności dokumentów z niezależnością statystyczną.

Wrażliwość na wspólne fragmenty. Oś główna i wybór checkpointu pozostają na pełnym H107. Przed odczytem modeli zapisano dodatkową analizę bez dokumentów z jakimkolwiek trafieniem 13-gramowym wobec 9 plików 1.07: pozostaje 711 dokumentów wyboru (582 307 tokenów z EOS) i 720 dokumentów werdyktu (629 809 tokenów z EOS). Podział i kolejność są zachowane. Dla raz wybranego checkpointu porównamy sparowane ΔBPB na pełnej części werdyktowej, jej dokumentach bez trafień oraz dokumentach z trafieniami, bez ponownego wyboru checkpointu. BPB to suma strat w bitach / suma bajtów; bootstrap wykonujemy po całych dokumentach. Odwrócenie znaku po odrzuceniu trafień zgłosimy jako zależność wyniku od pokrycia. Nie nazywamy części bez trafień semantycznie czystą ani rozłączną z danymi 1.06. Ta sama analiza opisowa obejmie H': po odrzuceniu 256 dokumentów z trafieniami pozostaje 1 305 dokumentów i 747 491 tokenów z EOS. Raportujemy pełne H' oraz części bez trafień i z trafieniami dla tego samego checkpointu, bez ponownego wyboru. Pełne H' pozostaje kontrolą w warunku (a); podzbiór jej nie zastępuje.

Baza porównania. avg10 1.07 porównujemy z avg10 1.06, a pojedynczy checkpoint z 1.06@13 848. Samo avg10 1.06 obniża loss heldoutu o ok. 0,045 nat i podnosi BLiMP o ok. 1 pkt, więc zestawienie avg10 z pojedynczym checkpointem przypisałoby danym efekt uśredniania.

Wybór checkpointu do wydania. Jedyne kryterium to najniższe BPB na połowie heldoutu przeznaczonej do wyboru. Tak samo wybieramy formę: pojedynczy checkpoint albo avg10.

Werdykt „lepszy niż 1.06”. Na wybranym checkpoincie, liczony raz, wymaga jednocześnie:

(a) spadku BPB na połowie werdyktowej heldoutu PL, $z < -2$, i braku wzrostu na drugim heldoucie;

(b) ruchu w górę na co najmniej jednej osi EN i jednej PL z rodziny w tab. 9, według procedury Holma przy $\alpha = 0{,}05$ dla 8 osi;

(c) braku ruchu w dół według tej samej procedury na jakiejkolwiek osi rodziny.

Ruch w dół na osi X zmienia werdykt na „lepszy z kosztem na X”. Bez (a) werdykt brzmi co najwyżej „inny”. Bez poprawki fałszywy „koszt” w (c) przy 8 osiach i progu $z < -2$ pojawiałby się w ok. 1 na 6 biegów. Nie liczymy średniej po zadaniach i nie układamy rankingu (arXiv:2203.08242). Osi nie dobieramy po wynikach. Nowa oś może dojść tylko jako opisowa.

Moc. Minimalna wykrywalna różnica przy mocy 80 % i najostrzejszym kroku Holma to $3{,}57\,\sigma$. Już samo SE par daje co najmniej ok. 3 pkt na ARC-C ($n = 1\,172$) i 1,6 pkt na MedMCQA. Tabelę dla wszystkich osi, z z_k, publikujemy przed startem. Mniejsza różnica bez ruchu oznacza brak rozstrzygnięcia, a nie „bez zmian”.

Bezpiecznik osi. Spadek osi EN z rodziny ($z < -2$, bez poprawki) w punkcie kadencji odnotowujemy w tej samej godzinie. Biegu nie zatrzymujemy automatycznie, decyzję o jego kontynuacji podejmujemy osobno.

10 Koszt, maszyny i logistyka danych

Źródła liczb: [R] odczyt rynku vast.ai 01.11, 18:16 UTC (sha ea0cccb7), [S] log strażnika konta instancji partii 1 do 23:43 UTC (245798bf), [K] pełny log tego strażnika do usunięcia instancji (6175ed03), [T] log treningu ramienia C (72be455d), [N] notatki projektu z 01.11. Pliki źródeł są w repozytorium wewnętrznym projektu, a nie w repozytorium benchmarków ani na HF. Oznaczenie [szacunek] to rachunek, nie pomiar.

Zmierzone tempo. Slayer 1B (1 073,9 mln parametrów, krok 1 048 576 tokenów) trenuje na jednej karcie RTX 4090 z prędkością **12 286–12 299 tok/s**, czyli ok. 85,3 s na krok [T]. Pomiar pochodzi z partii 1: jedno ramię na jednej karcie, bez treningu rozproszonego. Skan przecieku uruchomiony obok na procesorach tej samej maszyny nie zmienił tempa (12 297 tok/s w trakcie skanu, 12 300 przed nim [N]). Niezależny pomiar zespołu benchmarków na innej maszynie 1×4090 (eksperyment wygaszania, `research/slayer-1b/wygaszanie`) daje **11 435–11 440 tok/s** (91,7 s na krok). Tempa na 8 kartach (DDP) nie zmierzyliśmy. Do rachunku przyjmujemy sprawność skalowania 0,88 [szacunek], czyli ok. 86,5 tys. tok/s na maszynie 8×4090 z naszego pomiaru; przy tempie zespołu benchmarków wychodzi ok. 80,5 tys. tok/s, a czas etapów jest o ok. 7 % dłuższy (1.07: ok. 31 h zamiast 29 h).

Ceny (vast.ai, 01.11, 18:16 UTC [R]). Stawka obejmuje GPU i dysk wymagany przez dany bieg. Opłata za dysk nie jest pomijalna: przy 250 GB i 0,53 $/GB/miesiąc dodaje 0,19 $/h do 0,80 $/h za dwie karty.

maszyna	dysk	ofert	min [$/h]	mediana [$/h]
8× RTX 4090	500 GB	6	4,19	6,56
8× RTX 5090	500 GB	27	4,34	6,42
2× RTX 4090	250 GB	36	0,79	1,09
1× RTX 4090	100 GB	40	0,39	0,51

Filtr: oferty zweryfikowane, `reliability` $\geq 0{,}98$, na żądanie. Rynek zmienia się szybko: o 17:58 UTC najtańsze 8×4090 kosztowało 2,94 $/h, a 18 minut później 4,19 $/h. Tempa Slayera na RTX 5090 nie zmierzyliśmy, więc przed wyborem maszyny mierzymy 10 minut na obu typach (ok. 1 $).

Koszt etapów [szacunek]. Czas to liczba nowych tokenów podzielona przez 86,5 tys. tok/s, a koszt to czas razy stawka 8×4090 z tabeli (min–mediana). Slayer 1.06 widział 14 524 133 431 tokenów (sekcja 1).

etap	nowych tokenów	czas	koszt GPU
1.07 (dziś)	9 mld	29 h	121–190 $
do 40 mld łącznie	25,5 mld	82 h	343–537 $
do 100 mld łącznie	85,5 mld	275 h	1 150–1 800 $

Poza GPU dochodzą: ewaluacja na osobnej karcie 1×4090 (ok. 12 punktów pełnej tablicy po 989 s zmierzonych na A100, czyli ok. 3,3 h, plus 10 punktów samego lossu do avg10; tempa tablicy na 4090 nie zmierzyliśmy, więc przyjmujemy 4–12 h, ok. 2–6 $ na 9 mld [szacunek]), 10 minut pomiaru tempa przed biegiem (ok. 0,5–1 $) i transfer danych (pobieranie 2,67 $/TB, wysyłanie

4 $/TB [R]). Budowa i skan danych idą na procesorach maszyny, która i tak jest opłacona (niżej), więc nie dokładają wynajmu.

Partia 1 (sonda 1.07b): rozliczenie końcowe. Instancja 58683982: 2×4090, dysk 250 GB, stawka 0,985 $/h, działała od 16:45:10 UTC 01.11 do 03:09:18 UTC 02.11, czyli 10 h 24 min. Kontener ma limit **46 rdzeni** (`cpu.max` 4608000/100000) i **181 GiB RAM** (`memory.max`), choć `nproc` i `free` pokazują 192 rdzenie i 377 GB hosta (odczyt 19:21 UTC). W stanie pracy saldo spadało w tempie 0,997 $/h. W czasie pobierania danych tempo było wyższe, ok. 1,2 $/h, przez opłaty za transfer [S]. Saldo: 12,411 $ przy starcie, 1,944 $ po usunięciu [K]. **Koszt całej partii 1: 10,47 $**, średnio ok. 1,01 $/h z transferem. Obejmuje trening czterech ramion, pełną ewaluację ramion i punktu 1.06, budowę i czyszczenie danych 1.07 oraz skany przecieku heldoutów. Instancję usunął strażnik konta przy progu salda 2 $ [K]. Kopie danych, wyników i wag były na stacji od 02:11 UTC, więc wcześniejsze ręczne usunięcie oszczędziłoby ok. 0,9 $.

Logistyka danych.

- **Łącze stacji wysyła wolno:** 0,3 MB/s na jednym strumieniu i 1,6 MB/s na dwunastu [N]. 18 GB danych 1.07 przez stację to kilka godzin. Dane powstają więc na maszynach vast i przechodzą **z węzła na węzeł** (jednorazowy klucz SSH tylko do odczytu jednego katalogu, potem `sha256sum -c`, warunki w sekcji 4). Pobieranie z węzła na stację też jest wolne na jednym strumieniu (ok. 0,5 MB/s). Równolegle, w 24 strumieniach po 128 MiB przez proxy SSH, osiąga ok. 7–8 MB/s: 9 plików danych 1.07 (17 GB) i wagi czterech ramion (17,2 GB) przeszły w ok. 35–40 min każde [K, N].
- **Procesory węzła partii 1:** trening zajmuje 2 z 46 rdzeni kontenera. Na pozostałych, z priorytetem `nice 19`, budujemy dane 1.07 i skanujemy je na przeciek bez dodatkowego wynajmu. Limit pamięci kontenera (181 GiB) przekroczyły o 19:13 UTC dwie powtórki naraz ze złożeniem EN (OOM, trening przeżył), dlatego biegi danych i skany idą po kolei, łącznie do ok. 40 procesów [N].
- **Maszynę** 8× **wynajmujemy dopiero, gdy dane są gotowe i czyste**, żeby karty nie stały. Tempo skanu: ok. 1 h na 9 mld [szacunek, N].
- **Dysk maszyny 1.07: 500 GB.** Checkpointy ewaluacji i avg10 to 22 pliki, razem ok. 195 GB (konfiguracja launchera [N]), do tego oczyszczone dane ok. 18 GB i ich sklejona kopia ok. 18 GB. Karta ewaluacji ciągnie checkpointy z maszyny 1.07 (ok. 195 GB po 4 $/TB wysyłki i 2,67 $/TB pobrania, razem ok. 1,3 $ [szacunek]).

Zabezpieczenia kosztu. Każda wynajęta maszyna ma dwa niezależne bezpieczniki: (1) na węźle, uruchomiony jako pierwsze polecenie (`bezpiecznik.py`, usunięcie instancji kluczem instancji po zadanym czasie); (2) po stronie konta na stacji (`straznik_wynajmu.py`): usunięcie po limicie czasu albo przy saldzie poniżej 2 $. Ręczne usunięcie maszyny następuje dopiero po pobraniu wyników i na wyraźne polecenie właściciela konta. Przy partii 1 próg salda zadziałał wcześniej niż limit czasu: strażnik usunął instancję o 03:09:18 UTC przy saldzie 1,944 $, zamiast o 03:37 UTC [K]. Ostatnie pakowanie wyników zaplanowano więc najpóźniej na 02:30 UTC; ewaluacja skończyła się o 01:42 UTC.

Czego te liczby nie mówią. Sprawność 8 kart (0,88) i tempo RTX 5090 to założenia do zmierzenia. Ceny zmieniają się w ciągu minut. Koszty etapów 40 i 100 mld zakładają ten sam model 1B i ten sam kod treningu.

11 Ograniczenia: czego wynik nie dowodzi

- **Szum jest dolną granicą.** z_k to jedna realizacja: dwa checkpointy jednego biegu, 48 kroków od siebie. Nie obejmuje szumu seeda ani kolejności danych, więc prawdziwy szum może być większy, a „ruch" przy $|\Delta|$ blisko $2\,z_k$ może okazać się szumem.
- **1.07 nie jest eksperymentem kontrolowanym.** Zmienia jednocześnie dane, ich kolejność i liczbę kroków, a nie ma ramienia kontrolnego. Werdykt „lepszy niż 1.06" dotyczy całego setupu i nie przypisuje zysku żadnej pojedynczej decyzji (np. udziałowi EN albo powtórce PL).
- **Małe dodatki są nieidentyfikowalne.** Składnik rzędu 0,3 % mieszanki (dane F/K z sondy) nie daje w 1.07 osobnego, mierzalnego efektu.
- **Przeciek.** Skan 13-gramów nie wykrywa parafraz ani tłumaczeń pozycji testów. Zadania oznaczone przeciekiem czytamy tylko na pozycjach bez trafień, co zmniejsza moc porównania. EWoK nie jest w indeksie skanu, więc nie jest osią.
- **Przeniesienie z literatury.** Prace z sekcji 6 mają inną skalę, inny język albo inny harmonogram LR niż Slayer. Ich wyniki są dla nas hipotezą, a nie oczekiwanym zyskiem.
- **Sonda 1.07b ma małą moc.** Ramię to 105 mln tokenów i 100 kroków. Brak ruchu w sondzie nie wyklucza efektu w skali 1.07, a ruch w sondzie nie gwarantuje go w 1.07. Z 15 zadań z przeciekiem w bazie sondy nie wyciągamy wniosków, bo przeciek jest niesymetryczny między ramionami (F i K podmieniają część dokumentów C, a C2 jest inną próbką tej samej puli).
- **Panel 200 pozycji.** Klasyfikacja „na poziomie losowym" w sekcji 2 oznacza, że panel nie wykazał umiejętności. Nie oznacza, że model jej nie ma ani że danymi nie da się jej nauczyć.

12 Po pretreningu: SFT, preferencje i sprawdzalna poprawność

Miejsce w setupie. Przygotowywany etap 1.07 to dalszy pretrening na tekście; sam wzrost korpusu nie jest RLHF. Po wyborze checkpointu bazy można dostrajać sposób odpowiadania: trzymanie się polecenia, format, język i stosowanie posiadanych umiejętności. Nie deklarujemy, że etap preferencji zastępuje brakujące dane bazowe, ani że nie może zmienić wyników wiedzy. Wpływ na każdą z tych osi trzeba zmierzyć oddzielnie. Poniższa ścieżka jest **planem osobnego etapu**, a nie dodatkowym uruchomionym procesem w dzisiejszym treningu.

SFT: demonstracje poprawnego zachowania. Nadzorowane dostrajanie wykorzystuje pary polecenie–odpowiedź. Ouyang i in., arXiv:2203.02155, opisują demonstracje do SFT, następnie rankingi odpowiedzi od ludzi i uczenie z takiej informacji zwrotnej. Dla Slayera kandydatem są własne, sprawdzone demonstracje PL/EN oraz ludzkie dane o jasnym pochodzeniu. Nie kopiujemy formatów ani pozycji z testów, na których będziemy mierzyć efekt. Ocenę etapów robimy osobno: baza, model po SFT i model po preferencjach. Nie przypisujemy poprawy wynikającej z SFT późniejszemu RLHF.

RLHF: uczenie z preferencji ludzi. Dla tego etapu potrzebne są różne odpowiedzi na to samo polecenie oraz ocena, którą człowiek uważa za lepszą. Klasyczny schemat dopasowuje model nagrody do rankingów, a potem aktualizuje model językowy przez uczenie ze wzmocnieniem, z kontrolą odejścia od modelu odniesienia. Nie jest to wybór poprawnej litery z gotowego klucza.

Rafailov i in., arXiv:2305.18290, proponują *Direct Preference Optimization* (DPO): bezpośrednią optymalizację na parach preferencji, bez osobnego dopasowywania modelu nagrody i bez prób-

kowania z modelu w czasie tej optymalizacji. To prostszy kandydat do późniejszej próby uczenia preferencji, **nie synonim klasycznego algorytmu RLHF**. Wyniki autorów na sentymencie, streszczaniu i dialogu nie są dowodem skuteczności DPO na Slayerze PL+EN ani kosztorysem naszego etapu. Nie wybieramy algorytmu wyłącznie po nazwie lub deklaracji prostoty.

Dane preferencji: kandydaci, nie gotowy wsad. Wstępna kwalifikacja licencji z 1 listopada wskazuje ludzkie rozmowy i rankingi OpenAssistant OASST1/OASST2 (Apache-2.0) oraz ludzkie dane Aya (Apache-2.0) do SFT. HH-RLHF (MIT) ma oceny ludzi i odpowiedzi modelu Anthropic, z adnotacją pochodzenia w karcie. To kwalifikacja źródeł, a nie receipt zbudowanego datasetu i nie dowód wystarczającego pokrycia PL. Rewizja, pochodzenie generatora, podzbiór, licencja i reguła R1 muszą być rozstrzygnięte przed użyciem; obowiązują także PII i dekontaminacja z sekcji 4.

Własne rankingi autora są użyteczne szczególnie dla polskiego. Można oceniać parami odpowiedzi własnego Slayera, z ukrytą tożsamością wariantu i kolejnością odpowiedzi losowaną przed oceną. Kryteria poprawności, wykonania polecenia i stylu należy zapisywać osobno, żeby preferencja płynnego stylu nie została uznana za poprawę faktów. Pule uczenia i oceny trzeba rozdzielić po dokumentach i zadaniach.

RLVR: osobno sprawdzalna poprawność i format. DeepSeek-R1, arXiv:2501.12948v1, rozdziela w §2.2 nagrodę poprawności opartą na regułach od nagrody formatu. Reguła sprawdzania może być deterministyczna, choć odpowiedzi są próbkowane. GRPO to algorytm aktualizacji, a RLVR opisuje rodzaj nagrody; nie są to synonimy. W §2.4 autorzy wskazują, że małe modele destylowane trenowano przez SFT bez RL. Ich wyniki **nie dowodzą skuteczności bezpośredniego RLVR** na dowolnej małej bazie.

Dla Slayera RLVR pozostaje kandydatem do odrębnej próby na zadaniach, dla których mamy odporny na obejścia weryfikator, np. obliczenie lub test kodu. Weryfikator musi odróżniać poprawną treść od samego poprawnego zapisu. Nie uruchamiamy RLVR jako sposobu naprawienia nieznanej przyczyny słabego wyniku ani bez niezależnych zadań oceny.

Warunek przejścia do następnego etapu. Przed próbą trzeba wskazać jej umiejętność docelową, dane i ich pochodzenie, checkpoint startowy, kontrolę bez nowego etapu, budżet i regułę oceny. Pomiar obejmuje wykonanie instrukcji, sprawdzalną poprawność, ślepe preferencje na odłożonych poleceniach oraz koszt dla PL/EN i bazowych umiejętności. Wybór checkpointu odbywa się na walidacji, a nie przez szukanie najlepszego testu po wynikach. Preferencje, format i wiedza mają osobne wyniki; poprawa jednego z nich nie jest automatycznie poprawą pozostałych. Żadna z tych propozycji nie wstrzymuje budowy danych bazowych 1.07 ani nie oznacza, że post-training został już wykonany.

13 Synteza: pakiet dla zespołu treningowego

Stan wykonania. Przygotowano dane zakodowane tokenizerem Slayera, procedurę kontroli danych oraz projekt treningu i pomiaru. Nie wykonano jeszcze treningu modelu 1.07. Niniejszy dokument jest materiałem do przeglądu przez zespół treningowy, a nie raportem o poprawie modelu ani zgodą na uruchomienie biegu.

Co jest przygotowane.

- **Zbiór po kontroli v2:** 8 891 005 707 tokenów w 9 plikach. Polski web zawiera 3 110 430 927 tokenów, powtórka polskiego 1 894 295 941, mieszany angielski 1 650 618 814, a dodatkowy FineWeb-Edu 2 235 660 025. Liczby opisują gotowe pliki, nie deklarowaną wielkość źródeł.

- **Kontrola jakości:** maskowanie danych osobowych, skan dokumentów wobec indeksów testów, wycięcie wskazanych dokumentów i porównanie zachowanych dokumentów bajt w bajt. Polski web po dodatkowym maskowaniu przeszedł ponowny pełny skan. Próbki zgodności tokenów ze źródłem wyniosły 1 000/1 000 dla każdego sprawdzanego pliku.
- **Uzupełnienie po recenzji:** indeks dodatkowy obejmuje 5 652 pozycje ARC-Easy EN, ARC-Easy-PL i angielskich oryginałów Belebele. Łączny zakres indeksów wynosi 401 450 pozycji. Dodatkowo usunięto 103 dokumenty EN (421 063 tokeny); suma zbioru powyżej uwzględnia tę zmianę.
- **Powtórka jest celowa.** Dokładne kopie angielskich dokumentów z puli 1.06 wykluczono, ale nie wykonano pełnej deduplikacji bliskich kopii. Rozłączność identyfikatorów polskiego webu nie jest dowodem braku podobnych tekstów. Tak ograniczamy twierdzenie o nowości danych.

Wynik zakończonej sondy. Dwie niezależne implementacje uzgodniły główny odczyt eksperymentu F/K przy niezmienionych progach (sekcja 7). F nie spełnia warunku formatu. K spełnia regułę ruchu BPB poprawnej odpowiedzi w dół, a poprawa występuje także w grupie kontrolnej. To brak potwierdzenia przewidywanej swoistości dziedzinowej, nie brak sukcesu metryki BPB. Gotowy zbiór powyżej pozostaje bez zmian; decyzja o przeniesieniu danych do 1.07 należy do zespołu. Nie zamieniamy przewidywania swoistości w nowe kryterium sukcesu po obejrzeniu wyniku.

Co zmieniła recenzja.

1. **Wynik modelu nie jest automatycznie efektem danych.** Pełny bieg zmienia mieszankę, długość treningu i sposób przygotowania wydania. Porównanie z ramieniem B ma ten sam budżet tylko na odcinku 13 848→13 998. Zachowane wyniki B pokrywają cztery osie: ARC-C cloze, MedMCQA cloze, MultiBLiMP i WikiText-2. Dla tych osi można policzyć kontrast Δ_{dane}; pozostałe osie nie mają takiej kontroli bez dodatkowego ramienia.
2. **Metryki sprawdzono na kontroli ujemnej.** BPB poprawnej odpowiedzi zmieniało się silnie po dalszym treningu bez nowych danych, więc nie jest samodzielną osią werdyktu. Trafność liter również pozostaje opisowa. Rodzinę ocen, poprawkę Holma i model szumu definiuje sekcja 9.
3. **Wybór oddzielono od oceny.** Zbudowany H107 ma dwie części po 1 056 całych dokumentów: do wyboru checkpointu (1 042 856 tokenów) i do werdyktu (1 058 519 tokenów). Podział nie dowodzi niezależności statystycznej. Zbudowany H' spoza HPLT ma 1 561 dokumentów i 1 050 043 tokeny. W 9 plikach 1.07 nie ma jego pełnych kopii, lecz 256/1 561 dokumentów (16,4 %) ma wspólny 13-gram; nie deklarujemy pełnej rozłączności. Zbiór `24c704ec` pozostaje wyłącznie opisowym pomiarem retencji: części rdzenia i prawa występują w powtórce, a części EN i web widział wcześniej model 1.06.
4. **Porównujemy ten sam rodzaj artefaktu.** avg10 modelu 1.07 porównujemy z avg10 modelu 1.06, a pojedynczy checkpoint z pojedynczym. Poprawa wynikająca z uśrednienia nie może być przypisana nowym danym.
5. **Wygaszanie nie jest niezbadaną hipotezą.** Po 150 krokach zmiana lossu wobec 1.06 wyniosła −0,0503911 nat dla ramienia z wygaszaniem (A) i −0,0034372 nat dla stałego LR (B). Kontrast A−B wynosi −0,0469539 nat; to jemu odpowiada zaokrąglone −0,0470 nat (SE 0,0006), a nie zmianie A względem 1.06. Zysk dla pełnego etapu 1.07 i porównanie jego gałęzi wydania z avg10 wymagają osobnego pomiaru.

Wykonane kontrole i pozostałe ograniczenia. H107 jest zbudowany i ma zgodne sumy manifestu. Test wobec 9 plików 1.07 v2 nie znalazł identycznych pełnych dokumentów ani wspólnych prefiksów 64-tokenowych wśród 2 112 dokumentów H107. Opisowy skan wykazał wspólny 13-gram w 681/2 112 dokumentach H107 (32,24 %). To odsetek dokumentów z trafieniem, nie wspólnych tokenów ani dowód zapamiętania. Pełny H107 pozostaje osią główną; dla tego samego raz wybranego checkpointu dodatkowo raportujemy wynik na dokumentach z trafieniem i bez niego, bez zmiany progów lub ponownego wyboru. Tak samo opisowo sprawdzimy H': jego część bez trafień to 1 305 dokumentów / 747 491 tokenów z EOS; pełny H' nadal pozostaje dodatkową kontrolą, której podzbiór nie zastępuje. Kopii treści z packów 0–7 modelu 1.06 nie sprawdzono. Do ukończenia pozostają tabela szumu checkpointów i minimalnych wykrywalnych różnic oraz zamrożenie ostatecznego protokołu. Sam zapis reguły w dokumencie nie oznacza wykonania tych kontroli. Odbiór kopii v2 na stacji potwierdzono niezależną kontrolą sum 9/9 wobec właściwej bramki; starsza paczka v1 nie jest jej zamiennikiem. Archiwum HF pozostaje planem do potwierdzenia wysyłki i prywatności repozytorium. Nie deklarujemy publicznej redystrybucji ani dostępności na prośbę.

Decyzje zespołu przed kolejnym biegiem.

- zatwierdzenie mieszanki i budżetu oraz ewentualna gałąź wydania z wygaszaniem;
- decyzja o innych wstawkach formatu i wiedzy przy uwzględnieniu zakończonej sondy;
- ewentualne dodatkowe ramię B' dla czterech osi bez zachowanych wyników kontroli;
- kwalifikacja dalszych polskich źródeł (FinePDFs, ZPE, podręczniki AGH), z pomiarami jakości, przyrostu względem 1.06, praw, PII i przecieków, zamiast wyboru po samej objętości;
- oddzielny plan SFT i preferencji po bazie: nie są one wykonanym etapem tego przygotowania.